



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

이학석사 학위논문

딥 러닝을 활용한
재무제표 상 회계부정 탐지기법 연구

A study on accounting fraud detection
based on financial statements using deep learning

2019년 2월

서울대학교 융합과학기술대학원
수리정보과학과 디지털포렌식 전공
강 호 중

딥 러닝을 활용한
재무제표 상 회계부정 탐지기법 연구

A study on accounting fraud detection
based on financial statements using deep learning

지도교수 이 광 근
이 논문을 이학석사 학위논문으로 제출함

2018년 11월

서울대학교 융합과학기술대학원
수리정보과학과 디지털포렌식 전공
강 호 중

강호중의 석사학위논문을 인준함
2019년 1월

위 원 장 _____ 이 효 원 (인)

부 위 원 장 _____ 이 광 근 (인)

위 원 _____ 이 인 수 (인)

요약(국문초록)

회계부정이란 기업들이 매출액을 과대 계상하거나 지출액을 축소, 자산을 허위로 계상, 부채 축소, 비정상적인 자금을 운용하는 등 복잡하고 다양한 방법으로 기업의 재무 상태를 의도적으로 조작하는 비도덕적인 불법 행위를 뜻한다.

대표적인 사례인 미국의 엔론 사의 경우를 보면 회계부정으로 인한 추가하락으로 주주와 채권자들이 큰 손해를 입었을 뿐만 아니라 노후대책으로 자사주를 보유하고 있던 많은 사원들에게 회사 부도로 막대한 피해를 입히는 등 기업의 회계부정은 비단 해당 기업의 부실 문제를 넘어 국가 경제적인 측면 뿐만 아니라 사회적으로도 큰 악영향을 미칠 수 있다는 사실을 확인할 수 있다.

그에 따라 이러한 회계부정을 방지할 수 있는 새로운 포렌식 어카운팅 기법을 연구함으로써 기업과 직·간접적으로 이해관계를 가지고 있는 투자자 및 국가기관, 일반 국민들의 피해를 미연에 방지 할 뿐만 아니라 사회적으로 건전한 기업회계 문화 조성을 통하여 지속가능 기업이 늘어날 수 있는 환경을 넓혀가는데 도움이 되고자 하는 바가 이 연구의 기본 목적이다.

이 연구에서는 회계 부정 가능성을 예측하는 지표로 주로 단일지표를 사용한 기존 연구와 달리 재무제표 전체데이터를 사용하고 딥러닝 알고리즘을 활용한 지도학습 방법을 통하여 재무제표와 회계부정 사이의 연관성을 추적하고자 하였으며 학습자료로 금융감독원의 공시된 감리지적기업 데이터를 활용하였다.

본 논문에서는 공시된 재무제표 및 감리결과를 학습한 기계학습모

델이 회계부정을 사전탐지할 수 있는 포렌식 어카운팅 기법을 소개하고자 한다. 우선 감리지적된 사항에 따라 분류한 학습데이터로 기계학습 모델을 지도학습시킨 뒤 새로운 기업의 재무제표로 결과를 예측하는 방법을 제안한다. 그 과정에서 예측의 정확도를 검증하기 위하여 별도의 평가데이터로 훈련된 모델의 정확도를 검증하는 절차를 수행하였다. 또한 의사결정나무, 랜덤포레스트, 서포트벡터머신 등 다양한 기계학습 모델을 적용하여 실험함으로써 학습데이터에 질에 의존할 수 밖에 없는 딥 러닝 모델의 단점을 보완하고자 노력하였다.

회계부정은 기업의 재무 상태를 허위로 조작함으로써 개인이나 기관 투자자뿐 아니라 사회 전체에 악영향을 미치게 된다. 이에 따라 국가에서는 회계부정 방지를 위하여 관련 법규 및 제도를 개선하기 위하여 관계 기관이 노력하고 있으며 위반 시 처벌수위도 점차 높이고 있는 추세이다. 그럼에도 불구하고 여전히 투자 유치나 자금 확보 등을 목적으로 한 회계부정이 끊이지 않고 있으며 이렇게 조작되어 공시된 재무제표를 금융기관이나 투자자가 기업평가에 사용하여 잘못된 판단을 내리는 악순환이 계속 이루어지고 있다. 따라서 감리 및 실사 이전에 이미 공시된 자료로 회계부정을 신속하게 예측할 수 있는 탐지기법의 필요성이 갈수록 증가할 것으로 예상된다.

주요어: 회계부정, 재무제표, 딥 러닝, 머신러닝, 기계학습, 포렌식 어카운팅

학 번: 2017-28321

[목 차]

제1장 서 론	1
1. 연구의 배경 및 목적	1
2. 연구의 방법과 구성	3
제2장 관련 연구	5
1. 포렌식 어카운팅	5
가. 포렌식 어카운팅의 개념	5
2. 회계부정	7
가. 회계부정의 정의	8
나. 회계부정의 유형	9
3. 선행연구	11
가. 재무제표 비율에 관한 연구	11
나. 분기별 재무제표에 관한 연구	12
다. 기업부실 예측지표에 관한 연구	13
4. 재무제표	14
가. 재무상태표	15
나. 손익계산서	17
다. 재무비율 유형	18
제3장 기계학습	21
1. 기계학습 알고리즘	21
가. 의사결정나무	21

나. 랜덤포레스트	23
다. 서포트벡터머신	24
라. 인공신경망	26
2. 기계학습 알고리즘 도구	28
제4장 딥 러닝 모델	31
1. 딥 러닝의 개념	31
2. 학습유형	33
가. 지도학습	33
나. 비지도학습	35
다. 강화학습	36
3. 학습데이터	36
가. 학습데이터 선정	37
나. 데이터 정규화	40
다. 레이블 분류	41
4. 모델 학습 및 평가	42
가. 알고리즘 실험	42
(1) 의사결정나무 알고리즘 실험	42
(2) 랜덤포레스트 알고리즘 실험	44
(3) 서포트벡터머신 알고리즘 실험	45
(4) 멀티레이어퍼셉트론 알고리즘 실험	48
나. 딥 러닝 모델	48
(1) Activation Function	48
(2) Drop Out	50

(3) 신경망 설계	51
다. Confusion Matrix 평가	56
제5장 결론	57
1. 연구의 결과	57
2. 연구의 한계 및 향후 과제	57
참고문헌	60
Abstract(영문초록)	62

제1장 서론

1. 연구의 배경 및 목적

2001년 말 미국에서 일어난 엔론의 회계부정 사건으로 그동안 제도적, 조직적으로 계획된 부정적인 조작의 회계부정이 존재하고 있었음이 확인되었고 결과적으로 해당 기업의 파산을 초래하였다. 한 기업의 부정한 회계 운영으로 인해 수천 명의 실직자가 생겼고, 경제적으로 종업원들의 연금과 주식가치가 휴지가 되어 경제적 손실이 커져 지역의 경제생활이 마비에 이르렀다. 더불어 엔론의 외부 감사를 맡고 있던 아서 앤더슨사 또한 이 사건에 연루되어 영업을 하지 못하게 되고 결국 회사는 부도처리 되면서 파산에 이르게 된다. 이때부터 엔론은 기업사기와 회계부패의 상징이 되었고, 화이트칼라 범죄에 대한 경중과 단속의 기준이 되었고, 회계사기의 형벌을 강화하는 기폭제가 되었다.

엔론의 파산은 투명하지 못한 기업정신과 경영실패가 가져온 사건이었다. 또한 기업들의 부도덕한 운영, 분식회계 및 정경유착, 나아가 내부통제 시스템 등의 문제를 들 수 있다. 또한 형식적인 감독기능, 기업인들의 도덕적 무책임 등 경영시스템의 문제점을 다양하게 노출시킨 사건이다. 또한 시기적으로 에너지 공급 산업규제의 느슨한 틈타서 부적절한 방법으로 급속 성장하였던 도덕성을 상실한 기업의 잘못된 성장과 패해가 주는 사회적 아픔을 종식하는 결과를 보여준 사건이었다. 기업들의 자세와 정치, 내부시스템 등 운영하는 자들의 양심적인 도덕성이 매우 중요함을 인식하게 하는 사건이었다.

비단 해외 뿐만 아니라 국내에서도 IMF 당시 대우그룹이 41조원 규모의 분식회계를 한 사실이 드러나 공시된 재무자료를 신뢰하고 자금을 대출해 준 금융기관 및 국민들에게 큰 손해를 끼친 사실이 있으며, 최근에는 삼성바이오로직스가 분식회계 논란의 대상이 되기도 했다.

이렇듯 기업이 재무상태를 실제보다 긍정적으로 부풀려 재무제표상의 수치를 왜곡시키는 것을 분식회계라고 한다. 이는 투자자들의 판단을 왜곡시킴으로써 결과적으로 경제적 손해를 끼치는 일이기 때문에 엄격하게 법으로 금지되어 있지만, 실제로는 공인회계법인의 감사 절차를 진행하더라도 은닉된 분식회계 사실을 명확하게 밝혀 내기는 쉽지 않은 일이다. 예를 들어 채고자산의 가치를 장부에 과대계상하거나 허위의 매출전표를 발행하여 매출채권을 부풀리는 방법, 대손충당금을 축소하여 이익을 부풀리는 방법 등을 통하여 회사의 재무 건전성을 실제보다 높일 수 있다. 이와 반대로 조세부담을 회피하기 위하여 실제보다 이익을 적게 계상하는 역분식회계의 경우도 있다.

이러한 회계부정은 사후발각되는 경우가 대부분이며 발각될 때까지 오랜 기간동안 지속되기 마련이므로 통상 시간이 지날수록 위험성이 커진다고 볼 수 있다. 따라서 회계부정을 사전에 탐지하고 예측할 수 있는 기법에 대한 연구가 중요하고 그 정확도를 높이기 위한 지속적인 노력이 필요하다.

본 논문에서는 공시된 재무제표 데이터를 기반으로 기계학습 기법을 이용하여 세부조사가 필요한 범위를 선정할 수 있는 포렌식 어

카운팅 기법을 연구해보고자 한다. 이 과정에서 우선 기존 재무데이터를 이용한 포렌식 어카운팅 연구 사례들을 살펴보고 재무데이터와 감리결과를 미리 학습한 딥러닝 모델을 통해 인간의 지각능력으로 파악하기 힘든 재무제표의 패턴을 찾아내고자 노력하였다.

향후 이러한 딥러닝 모델이 재무제표 외의 다양한 비정형데이터를 어디까지 학습할 수 있는지, 모델의 학습에 있어 어떤 기계학습 알고리즘이 효율적인지 그리고 이러한 방식의 예측기법이 어느정도 정확도를 담보할 수 있는 것인지 등에 대해 이 논문을 통해 소개하고, 함께 고민해 보는 계기가 되었으면 하는 마음으로 이 논문을 작성하였다.

2. 연구의 방법과 구성

본 연구에서는 회계 부정 가능성을 예측하는 지표로 주로 단일지표를 사용한 기존 연구와 달리 딥러닝 알고리즘을 활용한 지도학습 방법을 통하여 재무제표와 회계부정 사이의 연관성을 추적하고자 하였으며 학습자료로 금융감독원의 공시된 감리지적기업 데이터를 활용하였다.

우선 금융감독원에서 제공하는 감리지적된 기업들의 지적사항을 유형별로 분류하여 온기 재무제표 데이터와 매칭한다. 그 후 지적사항 별로 분류된 학습데이터로 딥러닝 모델을 지도학습시킨 뒤 새로운 기업의 재무제표로 결과를 예측하는 방법을 사용하였다. 그 과정에서 예측의 정확도를 검증하기 위하여 별도의 평가데이터로 훈련된 모델의 정확도를 검증하는 절차를 수행하였다. 또한 의사결정나무, 랜덤포레스트, 서포트벡터머신, 멀티레이어퍼셉트론 등 다양한

기계학습 모델을 적용하여 실험함으로써 학습데이터에 질에 의존할 수 밖에 없는 딥 러닝 모델의 단점을 보완하고자 노력하였다.

제2장 관련연구

1. 포렌식 어카운팅

본 소절에서는 포렌식 어카운팅의 개념 및 기법을 살펴보고 이를 통해 디지털 포렌식의 기본적인 이해와 기존 포렌식 어카운팅 연구의 특징에 관해 소개한다.

가. 포렌식 어카운팅의 개념

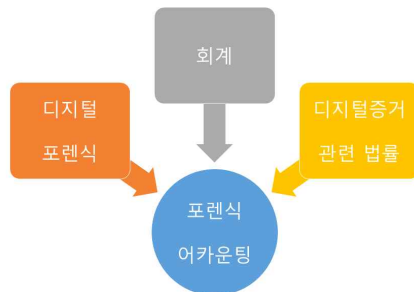
포렌식 어카운팅(Forensic Accounting)이란 디지털 포렌식의 한 분야로 기업의 회계 데이터에서 컴퓨터 포렌식 기술과 디지털 증거 관련 법률 지식을 통하여 회계부정과 관련된 법적 증거를 확보하는 모든 절차를 말한다.

디지털 포렌식(Digital Forensic)은 디지털 기기를 대상으로 한 법과학의 한 분야로, 컴퓨터와 디지털 기록 매체에 남겨진 법적 증거에 관한 것 등을 다루며 컴퓨터 법과학이라고도 한다. 정리하자면 디지털 포렌식은 “증거를 수집, 보존, 처리하는 과정에서 범정에 증거로 사용하기 위하여 과학적, 기술적인 기법을 사용하되 증거가치 상실이 없도록 하는 일련의 절차 또는 과정”을 뜻한다.¹⁾ 즉, 디지털 포렌식이란 디지털 기기를 매개체로 하여 발생한 특정 행위의 사실 관계를 법적으로 규명하고 증명하기 위한 절차적 방법을 말한다.

1) 이규안, 박대우, 고청심. “과학수사를 위한 디지털 포렌식”. GS 인터비전. 2011.

디지털포렌식은 정립된 개념이 아닌 진행 중인 개념이다. 포렌식은 “법정의, 공개토론이나 변론에 사용되는 수사와 법정에서 증거 또는 사실 관계를 확정하기 위하여 사용되는 기술이나 범죄와 관련된 증거물을 과학 적으로 조사하여 정보를 찾아내는 과정”이라는 의미를 갖는다. 다시 말하면, 디지털 포렌식은 “증거를 수집, 보존, 처리하는 과정에서 법정에서 증거로 사용하기 위하여 과학적, 기술적인 기법을 사용하되 증거 가치 상실이 없도록 하는 일련의 절차 또는 과정”을 뜻한다.²⁾

디지털 포렌식에 기초한 포렌식 어카운팅은 컴퓨터 포렌식 기술, 회계, 디지털 증거 관련법과 관련되는 영역으로 기업의 부정한 회계 활동과 관련, 법적 증거력이 있는 증거를 확보하는 모든 절차를 의미한다. 즉 포렌식 어카운팅은 기업의 숨겨진 매출이나 자산을 찾아내고 허위 비용계상을 탐지하는 등, 재무제표 상의 거짓된 숫자정보를 찾아내는 기능을 하게 된다. 따라서 포렌식 어카운팅은 적극적인 수사 방법으로 분류할 수 있으며 포렌식 어카운팅에 의하여 확보한 증거는 궁극적으로 합법적인 증거 자료로 사용될 수 있다.



[그림 1] 포렌식 어카운팅의 범위

2) 이규안, 박대우, 고청신. “과학수사를 위한 디지털포렌식”서울: GS인터비전. 2011.

대기업의 회계부정은 비단 회사와 투자자들 혹은 해당 직원들의 문제만이 아니라 국가 경제에 큰 악영향을 끼친다는 점에서 그 문제성이 심각하다. 또한 국가경제활동과 대외 신임도에 미치는 부정적인 영향을 고려할 때, 국가와 모든 국민들에게 불이익을 끼친다고 볼 수 있다. 따라서 기업의 회계 부정을 방지하고, 또한 부정한 일을 저지른 기업에 대한 적절하고 엄중한 처벌은 중요하며, 이는 기업 회계 부정의 근절과 재발을 방지하는데 핵심적인 요소이다. 이와 같은 과정에서 기업회계범죄에 대한 전문적이고 집중적인 수사기법이 필요한 것이며 필연적으로 포렌식 어카운팅이라는 전문분야가 등장하게 된 것이다.

기업의 회계 부정을 예방하기 위해 국가는 다양한 방법으로 제도와 법률을 개선하고자 노력하고 있다. 특히 회사의 자금세탁을 예방하기 위해 특정금융거래정보 이용에 관한 법률을 제정하여 금융정보분석원(Korea Financial Intelligence Unit)³⁾이라는 기구를 신설, 기업의 회계 부정과 맞서고 있으나 기업들은 회계 부정은 여전히 줄어들지 않고 있는 실정이며 오히려 회계 부정 방법들이 더욱 다양해지고 전문화 되고 있는 추세이다. 따라서 더욱 진화하는 회계 부정 사건과 맞서기 위해 법률과 제도 개선은 물론 체계적인 연구와 제도 개선, 수사기관의 전략 개발, 또한 사회의 전반적인 인식 전환의 중요성은 어느 때보다도 강조되어야 할 것이다.

2. 회계부정

3) www.kofiu.go.kr “금융정보분석원은 금융기관을 이용한 범죄자금의 자금 세탁행위와 외화의 불법유출을 방지하기 위하여 2001년에 설립되었다. 금융거래를 이용한 자금세탁행위를 규제하고 외화의 불법유출을 방지함으로써 범죄행위 예방과 건전하고 투명한 금융거래질서 확립에 기여하고자 한다.”

기업의 회계 부정은 해당 기업 뿐만 아니라 관련 투자자와 거래처의 동반 몰락을 의미한다. 따라서 회계부정은 반사회적 범죄라 할 수 있다. 자금횡령과 분식회계, 폰지 방식의 다단계투자자사기(Ponzi scheme), 사이버 범죄, 로비성 뇌물수수, 탈세 등 이러한 불법행위의 억제 및 피해의 최소화 방안을 모색하고, 회사들의 투명성을 높이기 위해 많은 국가들이 회계 제도를 개혁하기 위해 노력한다. 따라서 회사의 회계 정보를 검정하는 일은 국가의 중요한 사안이 되고 있다.

가. 회계부정의 정의

부정(Fraud)이란 의도적으로 조직의 자금을 절취하거나 횡령하는 것, 또는 재무제표 계정을 고의로 왜곡 표시하는 행위를 말한다.⁴⁾ 따라서 회계부정이란 “기업이 한 회계 연도의 영업실적과 연도 말의 재무상태 등의 재무정보를 재무제표에 기장하면서 재무정보를 왜곡을 의도하여 사실과 다르게 표시하는 것”이라고 할 수 있다.⁵⁾

분식회계 처벌 수위

	분식회계 내용	처벌 내용
엔론 (미국)	2001년 15억달러(약 1조7000억원) 회계부정	엔론 CEO 징역 24년형, 엔론은 그해 말 파산, 회계법인 아서앤더슨 폐업
대우그룹	1990년대말 20조원대 분식회계	2006년 김우중 전 회장 징역 8년6개월, 추징금 약 18조원 → 건강상 이유로 형집행정지, 2008년 특별사면
대우건설	2013년 3896억원 분식회계	법인 과징금 20억원, CEO(연봉 10억원) 과징금 1200만원, 삼일회계법인 과징금 10억6000만원
도시바 (일본)	2012~2013년 1300억엔 (약 1조4000억원) 순이익 과다계상	약 74억엔(약 800억원) 과징금 부과

[그림 1] 분식회계의 사례와 처벌 사례⁶⁾

4) 최영곤, “포렌식 부정적발 회계론”, 계명대학교출판부, 2011.

5) 조성원, “회계부정 예측에 관한 연구”, 박사학위논문, 단국대학교, 2007.

기업이 임의로 특정한 목적을 위해 기업의 실적을 좋게 또는 악화시키기 위하여 재무제표를 조작하게 되고, 한 번 시작된 조작은 이후에 재무제표에 계속적인 영향을 주게 된다. 즉, 기업이 신용도를 높게 하기 위해, 주가를 높이기 위해, 대출연장을 위해, 세금을 줄이기 위해, 배당을 적게 하기 위해, 사적인 이익을 위해서 등 여러 가지 이유로 분식, 역분식을 행하고 의도적으로 조작된 재무제표가 투자자 등 이해관계자의 의사결정에 영향을 미치게 되는 것이다

나. 회계부정의 유형

금융감독원의 감리결과 주요 감리지적사례를 유형별로 분류해보면 크게 당기손익, 잉여금, 자기자본 등에 영향을 미치는 사항(A)과 자산, 부채 과대 계상(B), 주식 미기재(C), 계정과목의 분류 오류 등(D), 회계기준외의 법규 위반사항(E) 등으로 구분하고 있음을 알 수 있다.⁷⁾ 이러한 유형 중 당기순이익이나 법인세에 영향을 미치지 않는 항목을 제외하면 크게 수익의 과대(소) 계상, 비용의 과대(소) 계상, 자산의 과대(소) 계상, 부채의 과대(소) 계상 4가지 유형으로 재분류할 수 있다.

구 분	차 변	대 변
재무상태표	자산	부채
		자본
손익계산서	순이익	수익
	비용	

[그림 2] 재무제표의 구조

6) <http://www.segye.com/newsView/20160714003294> 세계일보, 2016.07.14

7) 금융감독원, “2013년도 감사보고서 감리결과 주요 감리지적사례 및 유의사항”. 2014.

수익의 과대(소) 계상이란 기업의 매출을 비정상적으로 기록하는 행위이다. 일반적으로 기업의 거래는 거래의 형태, 시기, 조건, 상대방 등에 따라 다양한 형태로 발생하기 때문에 수익의 발생을 회계상 정확하게 인식하는 것은 매우 중요하며 동시에 어려운 일이다. 일례로 회사의 주가를 높이기 위해서, 투자자들로부터 자금을 조달하기 위하여 고의로 매출을 과대계상하거나 혹은 세부담을 경감시키기 위하여 매출을 은닉하는 경우가 있다.

비용의 과대(소) 계상이란 기업의 활동에 소요된 비용을 비정상적으로 기록함으로써 당기순이익을 임의적인 수준으로 조정하는 행위이다. 통상 허위경비 계상, 충당금계정 조정, 감가상각 추정사항(내용연수 및 잔존가액)의 변경 등의 방법을 통하여 비용을 조정하여 기업이 원하는 당기순이익을 만들어낸다.

자산의 과대(소) 계상이란 주로 재고자산 평가를 이용하여 매출원가를 조정, 기업의 당기순이익을 임의적으로 조정하는 것을 말한다. 재고자산을 과대계상하는 경우 매출원가가 과소평가됨에 따라 당기순이익이 증가하는 효과가 발생하며 기업의 유동비율이 증가하여 유동성이 양호한 것으로 보이는 효과가 있다.

부채의 과대(소) 계상이란 통상 부채를 장부 외 거래를 통하여 누락하거나 숨기는 경우를 말한다. 주로 실제 부채를 가공의 채권과 상계하여 장부에서 누락시키거나 각종 충당금을 과소계상하는 경우가 많다.

3. 선행연구

회계부정을 탐지하기 위한 다양한 경로를 찾기 위하여 이에 관한 선행연구를 조사하고 기업부실을 예측하는 방법론에 대하여 검토할 필요가 있다. 따라서 앞서 연구된 사례를 조사하여 다음과 같이 부실예측모형, 회계부정, 재무제표 비율, 기업부실 예측지표에 관한 연구들을 탐구하였다.

가. 재무제표 비율에 관한 연구

김억은 “재무제표상의 이상징후 탐지를 위한 포렌식 어카운팅 기법 연구” 논문에서 공시된 재무제표를 분석하여 기업 회계부정을 사전 탐지할 수 있는 포렌식 어카운팅 기법을 소개하였다. 또한 업종별 회계부정에 해당하는 기업과 아닌 기업의 재무제표를 대상으로 실험하여 본인이 제시한 이상징후에 대한 검증과정을 진행하였다.

이 연구에서 저자는 추세분석 및 수직분석, 수평분석 등 계정간 비율분석을 통하여 회계사건의 발생은 재무제표에서 관련된 여러 계정에 영향을 미친다는 점, 계정의 변화는 재무제표 중 재무상태표가 손익계산서보다 더 많이 존재한다는 점, 만일 계정의 변화가 손익계산서가 대차대조표보다 더 많이 존재한다면 이는 발생한 거래 데이터를 임의로 조정한다는 점 등을 실험의 결과로 말하고 있다.⁸⁾ 또한 동일 업종의 기업은 시장 흐름이나 외부 환경에 유사한 영향을 받는다는 점에 착안하여 업종별 분석을 통하여 기업의 계정별 등급을 산출하고 상세분석이 필요한 계정을 예측하고자 시도하였다.

8) 김억, “재무제표상의 이상징후 탐지를 위한 포렌식 어카운팅 기법 연구”, 고려대학교, 2010

그러나 본 실험에서 사용된 데이터는 정상기업이라 하여 회계부정을 저지르지 않았다고 보장할 수 없기에 허위양성을 판별할 수 없는 단점이 있다. 또한 예측모델이 얼마나 정확하게 회계부정을 예측할 수 있는지 정확하게 측정하기 위해서 분석에 사용되지 않은 새로운 평가데이터로 테스트하는 과정이 필요하다. 분석에 사용되었던 데이터를 평가에 다시 사용할 경우 데이터에 과적합된 편향된 결과가 나올 가능성이 있기 때문이며 따라서 앞으로 진행할 실험에서는 평가용 데이터를 별도로 구분하여 분석 및 학습에 사용하지 않기로 하였다.

이성원은 “재무비율의 위험징후를 통한 회계부정의 예측에 관한 연구 - 우리나라 감리지적기업을 중심으로” 논문에서 감리지적기업 및 감리 비지적기업을 대상으로 11개 주요 재무변수비율을 구한 뒤 T검증, 윌콕슨 순위합검증, 로지스틱 회귀분석을 실시하였으며 그 결과 비정상이익, 자산 수익률, 장부 가치에 대한 시장가치의 비율, 소규모 회계법인의 감사시행여부 등이 회계부정 지표로 영향력있음을 밝히고 있다. 또한 감리지적기업들의 경우 일반적으로 회계부정 사업년도에 비정상이익이 높은 특성이 있으며 비지적기업에 비하여 장부의 가치에 대한 시장가치 비율이 낮은 것으로 나타나고 회계부정 예측에 있어 산업평균이 유용한 기준이 될 수 있음을 말하고 있다.⁹⁾

나. 분기별 재무제표에 관한 연구

오은미는 “분기별 재무자료를 활용한 포렌식 어카운팅 기법” 논문

9) 이성원, “재무비율의 위험 징후를 통한 회계부정의 예측에 관한 연구”, 경기대학교, 2007

에서 감리지적기업과 일반기업 간 분기별 재무비율의 차이와 연도별 재무비율의 차이를 산출한 값으로 대응표본T 검정과 ANOVA 검정 이원배치분산분석을 실험하였으며 그 결과 부채비율, 총자본 이익률, 매출액 이익률, 총자산회전율의 유의확률이 유의미한 결과로 나왔다고 말하고 있다.¹⁰⁾

이 연구에서 감리지적기업 중 분기 공시자료가 있는 기업을 대상으로 유동비율, 당좌비율, 부채비율, 총자본 이익률, 자기자본 이익률, 매출액 이익률, 총자산 회전율을 산출하고 분석하였는데 기존 연구가 대부분 온기결산자료의 계정분석에 치중되고 있는데 반해 분기재무비율 분석에 중점을 두고 있다는 점에서 회계부정을 적시에 탐지할 수 있는 대안을 제시하였다고 할 수 있다. 그러나 분기보고서의 제출 의무가 주권상장법인과 특정 주권시장발행인 등(자본시장과 금융투자업에 관한 법률 제 159조 대상)에 제한되어 있기 때문에 표본 집단이 편중되어 있을 가능성을 배제하기 힘들다.

다. 기업부실 예측지표에 관한 연구

조성원은 “회계부정 예측에 관한 연구 - 기업부실 예측지표 중심으로” 논문에서 회계 부정을 예측할 수 있는 지표로 발생주의 영업 이익률에서 현금주의 영업이익률을 차감한 이익조정계수, 매출채권 회전기간, 재고자산 회전기간, 선급금 회전기간, 지급이자율, 수입이자율을 선정한 다음 예측지표와 회계부정 간의 상관관계를 증명하기 위한 가설을 설정하고 이 가설이 부실기업의 회계부정 예측에 유효한지를 연구하였다.

10) 오은미, “분기별 재무자료를 활용한 포렌식 어카운팅 기법”, 숭실대학교, 2014

본 연구는 재무제표와 감사보고서 등을 기초로 하여 회계부정가능성과 부실화 가능성을 판단하는 과정과 상호연계 계정을 결합한 회계부정가능성 및 부실 가능성을 분석하기 위하여 대차대조표의 자산계정, 부채계정, 자본계정과 손익계산서의 수익계정, 비용계정에 나타나는 계정과목 중 이익조정분석(매출채권, 재고자산, 선급금, 선수금)과 상각비 분석(감가상각비, 대손상각비)를 하였고, 차입금 분석(수입이자, 지급이자)을 하였고 감사의견과 비교분석을 하여 이익조정계수와 계정과목의 프로파일분석을 통해 회계부정가능성을 예측하는 데 일조했다고 주장하고 있다.¹¹⁾

이익조정 분석의 경우 매출채권 회전기간의 길이에 따라 이익조정계수의 폭이 커진대거나 대손 상각률의 추세분석에 따른 재무 위험성 예측 가능, 차입금의 지급이자율이 비정상적으로 낮은 경우 회계부정 가능성 예측 등의 방법을 제시하고 있으며 이를 감사의견과 비교하여 예측모델의 유효성을 높이고자 하였다.

하지만 제조업의 재무자료 및 정보자료 분석에 한정된 모델로 다양한 업종에 적용하지 못하는 한계를 보이고 있으며 재무제표만을 이용하는 연간 분석이기 때문에 사업연도가 종료된 후 결산이 끝난 시점에야 예측모델을 적용할 수 있는 한계가 있다. 향후 상반기 결산자료를 적용한 모델 연구로 회계부정 예측의 조기경보 역할을 기대할 수 있을 것이다.

4. 재무제표

재무제표를 구성하는 대표적인 보고서로는 재무상태표, 손익계산

11) 조성원, “회계부정 예측에 관한 연구 - 기업부실 예측지표 중심으로”, 박사논문, 단국대학교, 2007

서, 현금흐름표, 원가명세서 등이 있다. 재무상태표는 해당 기업의 결산 시점의 자산현황을 보여주는 보고서이고 손익계산서는 특정 기간 동안에 발생한 손익을 보여주는 보고서이다. 또한 현금흐름표는 기업의 현금 흐름, 원가명세서는 매출원가 부분을 상세히 기록한 보고서이다. 재무상태표와 손익계산서와 달리 현금흐름표와 원가명세서의 경우 기업에 따라 제출하지 않는 경우도 있으므로 본 논문에서는 재무제표분석 대상으로 재무상태표와 손익계산서를 선정하였다.

재무제표는 금융감독원의 전자공시시스템(DART ; Data Analysis, Retrieval and Transfer System)을 통하여 쉽게 조회할 수 있다. 전자공시시스템은 국내 상장법인 등이 제출한 사업보고서 및 감사보고서, 영업보고서 등 공시 자료들을 조회할 수 있도록 금융감독원에서 제공하는 기업정보 공개 시스템이다. 2000년 이후 상장법인 뿐만 아니라 코스닥시장 등록법인과 외부감사법 적용법인에 대해서도 모든 공시서류를 전자문서로 제출하도록 규정하였기 때문에 기업의 회계분석에 있어 매우 유용하다. 또한 최근에는 자체적으로 API 서비스를 제공하고 있어 대량의 데이터를 다운로드 받아 사용하기에도 적합하다.

가. 재무상태표

재무상태표는 기업이 특정시점 기준으로 보유중인 자산과 부채, 자본에 대한 보고서로 자산, 부채, 자본항목을 좌우 대칭형으로 보여준다. 요약하자면 기업자금의 조달과 운영 상태를 함축적으로 보여주는 보고서라고 할 수 있다. 재무상태표 및 손익계산서를 작성할 때 표시하여야 할 순서나 형식에 대한 강제규정은 없으나 한국채택

국제회계기준(K-IFRS) 재무상태표 분류체계와 계정과목은 다음 표와 같다.

가. 재무상태표의 분류체계와 계정과목 요약		
분류	설명	계정과목
자산	유동자산	현금 및 금융자산
		매출채권
		단기대여금
		신용보증
		미수이자
	투자자산	상품
		소모품
		투자부동산
		장기대여금
		실비자산(건물, 구축물, 기계장치, 차량운반구, 비품)
자산	유형자산	토지
		건물중간 자산
		비품집기(사무기기, 누계액)
		신입자산(특허권, 상표권, 실용신안권 등)
		영업권
	무형자산	컴퓨터(소프트웨어)
		판권권
		개발비
		영업권
		임차보증금
부채	유동부채	이연법인세자산
		장기미수금
		당기순이익잉여금부채
		매입채무
		신수금
	장기금융부채	미지급비용
		장기차입금
		사채
		확정급여부채
		제품보증충당부채
자본	납입자본	구조조정충당부채
		임대보증금
		이연법인세부채
		보통주 자본금
		우선주 자본금
	이익잉여금 (결손금)	주식발행초과금
		감자이익
		자기주식처분이익
		법정차입금
		임의차입금
자본	기타 자본 구성 요소	미지급이익잉여금
		자기주식
		주식발행비용차감
		감자자산
		자기주식처분손실
	기타 자본 구성 요소	매도가능금융자산평가손익
		재평가이익/손익
		외환차익

[표] 재무상태표 분류체계와 계정과목 요약¹²⁾

자산은 부채와 자본으로 이루어지는데, 유동자산인 당좌자산, 재고자산과 비유동자산인 투자자산, 유형자산, 무형자산 항목으로 구성되며 부채는 유동부채와 비유동부채로 구성된다. 자본은 자본금, 자본잉여금, 자본조정, 기타포괄손익 누계액, 이익잉여금으로 구성된다. 이러한 항목으로 구성된 재무상태표는 기업의 유동성, 안정성을 평가하는 기초자료가 된다. 상세계정은 각 기업에서 필요한 항목으로 명명하여 사용할 수 있다.

나. 손익계산서

손익계산서는 수익·비용대응원칙에 따라 기업의 일정기간동안 수익에 대한 보고서이다. 수익항목과 비용항목이 표기되며 이에 따른 이익, 손실을 보여준다. 손익은 수익에서 비용을 차감한 것이다. 한국채택 국제회계기준(K-IFRS) 손익계산서 분류체계와 계정과목은 다음 표와 같다.

12) <http://www.intn.co.kr/news/articleView.html?idxno=43604>, 국제신문사, 2012.12.20

항 목	설 명	계정과목
매출액 및 수익	상품, 제품, 용역의 대가	용역매출, 상품매출
매출원가	판매된 상품(또는 제품)의 매입원가(또는 제조원가)	매출원가 매입, 재고자산감모손실, 재고자산평가손실
매출총이익	매출액에서 매출원가를 차감한 총마진	매출총이익
기타수익	통상적으로 기업활동에서 발생한 중요한 수익으로서 위 매출액 또는 수익에 포함되지 않는 것	이자수익, 배당금수익, 임대료, 당기손익인식금융자산처분이익, 외환차익
물류원가	재화의 생산 후 고객 이전시까지 발생하는 원가	감가상각비, 보관료, 운송비, 광고선전비
관리비	영업활동에 필요한 제반 관리활동에 소요된 비용	급여, 임차료, 소모품비, 감가상각비, 통신비, 여비출장비, 대손상각비
금융원가	자금조달 활동에 소요된 이자비용 등의 원가	이자비용
기타비용	물류원가 관리비 및 금융원가에 속하지 않는 비용	당기손익인식금융자산처분손실, 당기손익인식금융자산평가손실, 외환차손, 기부금
지분법관련손익	지분법 적용대상인 관계기업과 조인트벤처의 당기 순손익에 대한 지분	지분법이익, 지분법손실
법인세비용차감전 순이익	매출총이익+기타수익-모든 당기비용(법인세비용 제외) 등 금액을 근거로 법인세비용 산출	
법인세비용	법인세비용차감전 순이익에 대하여 당기에 부담하여야 하는 법인세비용	법인세
계속영업이익	중단영업이 제외한 계속영업으로부터의 당기순손익	
중단영업관련손익	중단영업에 대한 세후 영업손익(즉 세후 영업중단 손익)과 중단영업에 속한 자산이나 처분자산감도의 처분으로 인하여 또는 손 공정가치의 측정으로 인하여 인식된 세후 손익	
당기순손익	법인세비용차감전 순이익에서 법인세비용을 차감한 금액(계속영업이익)에 중단영업관련손익을 가감한 금액 일정 기간이론 기업의 경영성과를 최종적으로 나타내는 단일 수치	
기타포괄손익	당기순이익의 계산에는 포함되지 않지만 총포괄손익에 포함되는 손익, 자본에 속한 기타포괄손익항목을 가산한 손익	
총포괄손익	당기순이익에 기타포괄손익항목을 가산한 손익	
주당이익	· 보통주 1주당이익 당기순이익을 보통주 가중평균주식으로 나눈 수치 · 중요한 지표로 포괄손익계산서 당기순이익 항목 밑에 별도로 표시하여 공시	

[표] 손익계산서 분류체계와 계정과목 요약13)

손익계산서는 매출액, 매출원가, 매출총이익, 기타수익, 판매비, 관리비, 영업이익, 법인세차감 전 순이익, 법인세비용, 계속사업이익, 중단사업 손익, 당기 순이익 등의 항목으로 구성된다. 이러한 보고서 내용을 통해 비용구조의 변화를 보는 것이 중요하다.

다. 재무비율 유형

재무비율은 재무제표에서 연관관계가 있는 특정 두 계정을 대입하여 수치화 하고 이를 이해하기 쉽도록 지표로 나타낸 것이다. 기업의 경영에 따른 유의미한 정보들을 처리하는 효율적인 방법이며, 그 수치에 따라 다양한 정보와 의미를 제공해 주기 때문에 투자자, 금융기관, 경영 자들의 의사결정에 영향을 주게 된다. 선행연구에 주로 사용된 재무비율의 유형에는 유동비율, 당좌비율, 부채비율, 총자산이익율, 자기자본이익율, 매출액이익율, 총자산회전율 등이 있다.

유동비율은 기업의 단기채무 상환능력을 판단하는 비율이다. 유동성의 기준을 1년으로 보고 1년 안에 현금화가 가능한 자산을 자수로, 부채를 모수로 나누어 비율을 구한다. 통상적으로 이 비율이 200% 이상 유지되는 기업은 유동성이 안전하다고 평가한다.

당좌비율은 유동자산 중 재고자산을 차감한 것으로 유동자산 중에서도 현금화가 빠른 자산의 비율을 뜻한다. 현금화가 빠른 자산을 유동부채로 나눈 비율로 신속비율이라고도 한다. 통상적으로 100% 이상이면 안전하다고 평가한다.

부채비율은 기업의 건전성을 평가하는 비율로 타인자본에 대한 의존도를 나타낸다. 총부채를 자기자본으로 나눈 비율로 안정성비율이라고도 한다. 통상적으로 100% 이하면 안전하다고 평가한다.

총자본이익율이란 기업에서 투자한 총자본에 대한 연간 이익의 비율을 말한다. 기업이 일정기간동안 어느 정도에 이익을 실현하였는가를 말하는 것으로 기업운용의 효율성을 나타내는 지표이다. 당기순이익을 총자본으로 나눈 비율이다. 이 비율이 높을수록 기업을 효

13) <http://www.intn.co.kr/news/articleView.html?idxno=43604>, 국제신문사, 2012.12.20

율적으로 운용되고 있는 것이다.

자기자본이익율이란 당기순이익을 자기자본으로 나눈 비율이다. 기업의 총자본은 주식으로 구성된 자기자본과 차입으로 구성된 타인자본이 있다. 자기자본이익율은 주주의 자본을 얼마만큼 잘 운영하여 수익을 올렸는가를 파악하는 지표이다. 기업의 성장성과 주주의 이익의 지표가 된다. 자기자본 이익률이 높을수록 주가가 높게 형성되는 경향이 있다.

매출액이익율은 당기순이익을 매출액으로 나눈 비율로 전반적인 영업활동의 효율성을 평가하는 지표가 된다.

총자산회전율은 총자산을 영업이익으로 나눈 비율로 총자산이 1년에 몇 번 회전하였는가를 나타내며 기업이 소유한 총자본을 얼마나 효율적으로 운영했느냐를 나타내는 지표이다.


제3장 기계 학습

1. 기계 학습 알고리즘

본 소절에서는 다양한 기계 학습 알고리즘들을 살펴보고 본 연구에 가장 적합한 알고리즘을 찾고서 적용하고자 노력하였다. 기존 인공지능의 대표적인 방법이었던 전문가 시스템의 단점을 보완하고자 시작된 기계 학습은 컴퓨터로 만든 모델이 인간처럼 학습하여 스스로 규칙(함수)을 만들어낼 수 있지 않을까 하는 시도에서 시작되었다. 전문가 시스템이 연역적 추론에 의존하는 데 반해 대부분의 기계 학습은 학습자료를 기반으로 한 통계적·귀납적 추론에 의존한다. 현재 이미지 분류 등 주로 인간이 직관적으로 분석하기 힘든 정도의 크고 복잡한 데이터로부터 변수들 간의 연관관계를 추정하는데 효율적으로 사용되고 있다. 본 논문에서는 딥러닝 모델과 비교분석할 알고리즘으로 가장 대중적으로 사용되고 있는 의사결정나무, 랜덤포레스트, 서포트벡터머신, 인공신경망 모델에 대하여 알아보았다.

가. 의사결정나무

의사결정나무(decision tree) 알고리즘은 데이터 마이닝 분야에서 일반적으로 사용되고 있으며 주로 지도학습 분야에서 유용하게 이용되고 있는 알고리즘이다. 입력 변수를 바탕으로 목표 변수의 값을 예측할 수 있는 모델을 만드는 것이 목표이며 트리 구조로 이루어진 각 노드들은 하나의 입력 변수, 하위 가지들은 입력 변수가 가능한 값에 각각 대응한다. 아래 그림은 의사결정나무 알고리즘을 적용한 예측 모델의 한 예를 보여준다.



[그림] 의사결정나무의 구조14)


의사결정나무 알고리즘은 결과를 해석하고 이해하기 쉬우며 대부분의 다른 알고리즘들이 데이터를 정규화해야 하는 반면 데이터를 전처리할 필요가 거의 없다는 장점이 있다. 또한 수치 자료와 범주 자료 모두에 적용 가능하며 인공신경망이 추론결과를 설명할 수 없는 블랙박스 모델임에 반해 결과에 대한 설명이 가능한 화이트박스 모델이다. 대규모의 데이터에도 적용가능한 안정적인 알고리즘이기도 하다.

그러나 휴리스틱 기법을 기반으로 하고 있기 때문에 최적의 결정 트리를 학습하는 것은 NP_완전문제로서 불가능하다고 알려져 있으며 여러 변수를 동시에 적용가능한 대부분의 알고리즘과 달리 오직 한 개의 변수만을 선택할 수 있는 큰 단점이 있다. 또한 다차원의 패턴을 가진 데이터를 적용할 경우 트리가 지나치게 복잡해지는 문제가 발생한다.

14) <https://medium.com/machine-learning-bites>

나. 랜덤포레스트

랜덤포레스트(random forest) 알고리즘은 분류나 검출, 회귀분석 등에 이용되는 기계학습 방법 중 하나로 다수의 의사결정나무으로 이루어진 학습 단계와 추론에 사용되는 테스트 단계로 구성되어 있다. 이 알고리즘의 가장 큰 특징은 상관관계가 없는 다수의 트리구조에서 나오는 임의성에 있다. 다수의 각 의사결정나무 구조들은 조금씩 다르며 독립적이기 때문에 각 트리들의 추론 결과 값들은 결과적으로 일반화되는 효과가 있으며 학습 역시 독립적으로 이루어지기 때문에 앙상블 효과15)를 기대할 수 있다. 각 결정트리로부터 나온 결과 값들을 평균 내지 곱하기, 혹은 과반수 투표 방식 등을 통해 일반적인 최종 결과 값을 도출한다. 아래 그림은 랜덤포레스트 알고리즘을 적용한 예측 모델의 한 예를 보여준다.



[그림] 랜덤포레스트의 구조16)

15) 앙상블 학습법(ensemble learning method) : 학습효과를 높이기 위해 다수의 알고리즘을 중복해서 사용하는 기계학습 방법

16) <https://www.researchgate.net/>

의사결정나무의 경우 학습데이터에 따라 결과 또는 성능의 편차가 크거나 소량의 데이터 변화에도 결정 트리의 구조가 완전히 달라지는 등의 단점이 있는데 반해 랜덤포레스트 알고리즘은 임의성에서 나오는 월등한 일반화 성능을 기대할 수 있고 학습 및 테스트 과정이 간편하고 빠를 뿐만 아니라 다차원의 입력변수 적용이 가능하다는 점, 그럼에도 불구하고 높은 정확도를 보여주고 있다는 점에서 유용한 기계학습 알고리즘으로 평가받고 있다.


다. 서포트벡터머신(SVM)

1990년대에서 2000년대 초반까지 기계학습분야에서 두각을 나타낸 알고리즘으로 러시아의 통계학자인 블라드미르 바프니크(Vladimir Vapnik)와 코리나 코르테스(Corinna Cortes)에 의해 1995년 발표된 기계학습 알고리즘이다. 2006년 토론토대학의 제프리 힌튼(Geoffrey Hinton) 교수가 심층신뢰망을 이용한 은닉층에서의 데이터 전처리 방법을 제시하기 전까지 우수한 성능으로 다방면에 이용되어왔다.

서포트벡터머신은 패턴 인식, 자료 분석을 위한 지도 학습 모델로 분류할 수 있으며 주로 분류와 회귀분석에 사용된다. 두 가지 유형의 카테고리 나뉘어진 데이터의 집합이 있을 때 이 알고리즘은 주어진 데이터 집합을 기반으로 새롭게 주어진 데이터가 어떤 카테고리로 분류될 것인지 예측하는 비확률적 이진 선형분류 모델을 만든다.¹⁷⁾ 선형분류 뿐만 아니라 비선형 분류에서도 사용가능한데 이를 위해서는 주어진 데이터를 더 높은 고차원으로 대응시켜야 하며 이과정에서 효율적인 계산을 위하여 적절한 커널함수를 정의한 SVM 구조를 설계, 초기 변수들을 사용해서 연산을 효과적으로 계

17) Vapnik, V. "The nature of statistical learning theory". Springer-Verlag New York. 2000.

산할 수 있도록 하였다.¹⁸⁾



[그림] 서포트벡터의 개념¹⁹⁾

일반적으로 선형분류의 경우 데이터를 분류하는 초평면은 다양한 형태로 나타날 수 있는데 그 중 가장 적절한 초평면을 선택하는 타당한 방법 중 하나는 카테고리 사이에서 제일 큰 마진을 가지는 초평면을 선택하는 방법이다. 즉, 초평면에서 제일 가까운 카테고리의 데이터 간 거리를 최대로 하는 초평면을 선택하는 알고리즘이 SVM이라고 할 수 있다.


SVM 알고리즘을 사용하여 문제를 해결한 사례를 살펴보면 텍스트와 하이퍼텍스트를 분류하는 데 있어 필요한 학습데이터의 양을 감소시킨 사례, 이미지 분류 작업 시 높은 정확도를 보인 사례, 화합물에서 단백질을 높은 정확도로 구분하는 의학분야 사례 등을 찾을 수 있다.

18) Press, William H.; Teukolsky, Saul A.; Vetterling, William T.; Flannery, B. P. "Numerical Recipes: The Art of Scientific Computing". Cambridge University Press. 2007.

19) <https://www.saedsayad.com/>

라. 인공신경망

인공신경망(artificial neural network) 알고리즘은 인간의 생물학적 중추신경계, 즉 뇌의 구조에서 영감을 얻어 설계된 통계학적 학습 알고리즘이다. 생물학적 뇌가 시냅스로 결합된 뉴런 세포로 이루어져 있는 것과 마찬가지로 인공 뉴런인 노드가 다수의 층으로 네트워크를 형성하여 시냅스 간 신호세기를 가중치 값으로 조절하여 복잡한 데이터에 숨겨져 있는 패턴을 탐지할 수 있는 모델을 만들 수 있다. 가중치란 노드 사이의 신호 세기를 의미하며 이는 훈련 및 예측 시 적용된다. 일반적으로 오차역전파법을 사용하는 다층 퍼셉트론 구조의 네트워크 구조를 통칭하나 생물학적 중추신경계를 모방한 모든 알고리즘을 말하는 더 큰 의미로 사용하기도 한다.




[그림] 사람의 뇌-신경계와 퍼셉트론 비교²⁰⁾

신경망모델은 다수의 입력 변수들 속에서 파악되지 않은 선형·비선형 함수를 추측하고 입력값에 해당하는 결과값(근사치)을 추론하는 경우에 많이 사용된다. 따라서 결과값이 나오는 과정을 설명할 수

20) 류성일, “4차 산업혁명을 이끄는 인공지능 딥 러닝을 중심으로”, kt BigData Project-TF, 2017.4.

없는 블랙박스 모델에 해당하며 결과적으로 학습데이터에 의존하여 노드 및 은닉층의 개수, 활성화 함수의 종류, 가중치의 수정 범위, 반복학습 횟수 등 네트워크 구조 수정을 통해서 모델의 성능 및 효율을 개선해 나갈 수 있다.



[그림] 인공신경망의 구조²¹⁾

최초의 신경망 모델이 1943년 워렌 맥컬록(Warren McCulloch)와 월터 피츠(Walter Pitts)에 의하여 연구된 이래 프랑크 로젠블라트(Frank Rosenblatt)의 퍼셉트론 알고리즘 등 많은 이론적 연구가 진행되었으나 단층 신경망의 경우 배타적 논리합 회로(exclusive-or circuit)를 처리하지 못한다는 점, 거대한 신경망의 경우 처리할 컴퓨터 성능이 뒷받침되지 못한다는 점에서 실제 주목할 만한 성과는 나오지 않았다. 그러나 1975년 폴 웨어보스(Paul Werbos)가 오차역전파법을 소개하면서 배타적 논리합 회로 문제를 효율적으로 해결할 수 있게 된 후 인공신경망은 SVM 등 기타 알고리즘의 성능을 추월하게 되었고 2000년대 이후 가장 관심을 받는 기계학습 알고리즘이 되었다.

21) <https://www.jeremyjordan.me/convolutional-neural-networks/>

2006년 이후 대부분의 기계학습 국제대회에서 신경망 기반 모델이 높은 정확도로 우승을 차지하고 있으며 실례로 IDSIA의 덴 크리스(Dan Ciresan)의 연구진은 IJCNN 2011 교통 표지판 인식 대회²²⁾, ISBI 2012 신경 구조의 분할의 전자 현미경 대회를 비롯하여 여러 패턴 인식 경연에서 여러 번 우승하였는데²³⁾ 그들의 신경망은 교통 표지판(IJCNN 2012) 또는 MINIST 필기 인식 분야에서 인간과 견줄만한 또는 인간을 넘어서는 인공 패턴 인식이라는 평가를 받고 있다.²⁴⁾

2. 기계학습 도구

기계학습 알고리즘을 개발하거나 실행할 수 있는 도구에는 여러 가지 종류가 있으나 본 논문에서는 실험에 아무런 제약없이 사용할 수 있는 공개 소프트웨어를 우선적으로 살펴보고 사용하고자 하였다. 우선 일반적으로 기계학습에 사용되는 프로그램으로는 텐서플로우(TensorFlow)나 사이킷런(Scikit-learn)과 같은 python 기반의 라이브러리, Keras, caffe, R, weka 등의 오픈소스 소프트웨어들이 주로 이용되고 있다.

아래는 2017년 깃헙(Github)과 Stack Overflow 내 활동, 그리고 Google 검색결과를 기반으로 기계학습에 유용한 23개의 오픈소스

22) D. C. Ciresan, U. Meier, J. Masci, J. Schmidhuber. Multi-Column Deep Neural Network for Traffic Sign Classification. Neural Networks, 2012.

23) D. Ciresan, A. Giusti, L. Gambardella, J. Schmidhuber. Deep Neural Networks Segment Neuronal Membranes in Electron Microscopy Images. In Advances in Neural Information Processing Systems (NIPS 2012), Lake Tahoe, 2012.

24) D. C. Ciresan, U. Meier, J. Schmidhuber. Multi-column Deep Neural Networks for Image Classification. IEEE Conf. on Computer Vision and Pattern Recognition CVPR 2012.

기계학습 라이브러리 순위를 나타낸 표이다. 이 표는 표준화된 점수를 보여주고 있으며 평균점수는 0으로, 1점 차이는 표준편차 1을 의미한다.

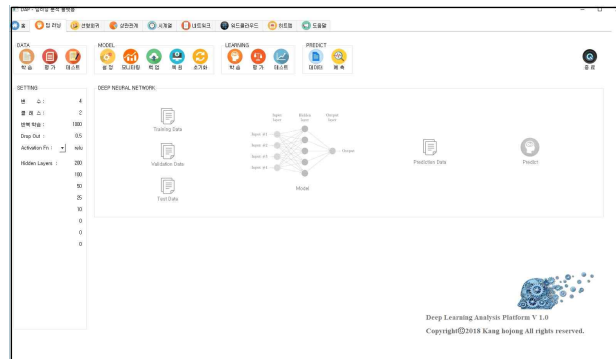
Library	Rank	Overall	Github	Stack Overflow	Google Results
tensorflow	1	10.87	4.25	4.37	2.24
keras	2	1.93	0.61	0.83	0.48
caffe	3	1.86	1.00	0.30	0.55
theano	4	0.76	-0.16	0.36	0.55
pytorch	5	0.48	-0.20	-0.30	0.98
sonnet	6	0.43	-0.33	-0.36	1.12
mxnet	7	0.10	0.12	-0.31	0.28
torch	8	0.01	-0.15	-0.01	0.17
cntk	9	-0.02	0.10	-0.28	0.17
dlib	10	-0.60	-0.40	-0.22	0.02
caffe2	11	-0.67	-0.27	-0.36	-0.04
chainer	12	-0.70	-0.40	-0.23	-0.07
paddlepaddle	13	-0.83	-0.27	-0.37	-0.20
deeplearning4j	14	-0.89	-0.06	-0.32	-0.51
lasagne	15	-1.11	-0.38	-0.29	-0.44
bigdl	16	-1.13	-0.46	-0.37	-0.30
dynet	17	-1.25	-0.47	-0.37	-0.42
apache singa	18	-1.34	-0.50	-0.37	-0.47
nvidia digits	19	-1.39	-0.41	-0.35	-0.64
matconvnet	20	-1.41	-0.49	-0.35	-0.58
tflearn	21	-1.45	-0.23	-0.28	-0.94
nervana neon	22	-1.65	-0.39	-0.37	-0.89
opennn	23	-1.97	-0.53	-0.37	-1.07

[그림] 오픈소스 기계학습 라이브러리 순위²⁵⁾

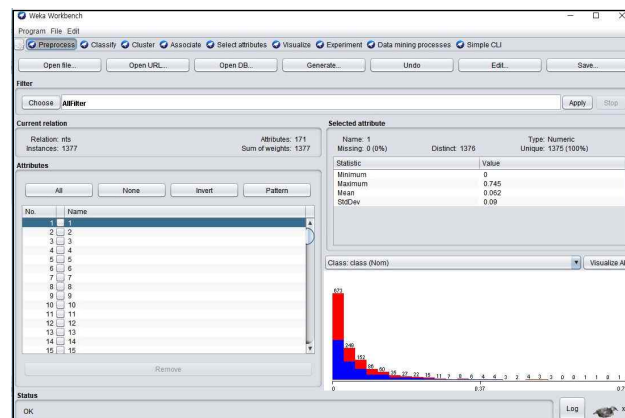
본 논문에서는 딥러닝 모델 실험을 위하여 가장 보편적으로 사용되고 있는 tensorflow 라이브러리를 사용하여 본 논문의 실험을 위해 별도로 제작한 DAP(Data Analysis Platform) 프로그램을 사용하기로 한다. DAP는 tensorflow의 contrib.learn.DNNClassifier 라이브러리를 주된 알고리즘으로 사용하며 반복되는 실험을 편리하게 진

25)<https://blog.thedataincubator.com/2017/10/ranking-popular-deep-learning-libraries-for-data-science/>

행하기 위하여 데이터 입출력 및 파라미터 설정 인터페이스를 구현한 Python 기반 GUI(Graphic User Interface) 프로그램이다. 이 외 기타 기계학습 알고리즘의 실험은 다양한 알고리즘을 사용할 수 있는 Weka를 사용하였다. Weka는 뉴질랜드 와이카토대학교에서 개발한 기계학습 소프트웨어로 학술연구에 대중적으로 사용되고 있으며 GNU 일반 공중 사용 허가서로 허가된 오픈소스 프로그램이다.



[그림] DAP 프로그램 구동 화면



[그림] Weka 프로그램 구동 화면

제4장 딥 러닝 모델

1. 딥 러닝의 개념

일반적으로 동일한 의미로 언급되고 있는 인공지능(Artificial Intelligence)과 기계학습(Machine Learning), 딥 러닝(Deep Learning) 용어의 정확한 개념은 다음과 같다.

우선 인공지능이란 기계학습과 딥러닝을 포함하는 최상위 개념으로 이전 전문가시스템을 포함한 기계를 이용하여 만든 모든 알고리즘을 말한다. 그 중 기계학습은 인공지능의 한 분야로 기계가 일일이 프로그램으로 명시하지 않은 함수를 데이터의 특징으로부터 학습하여 새로운 데이터의 결과값을 추론할 수 있도록 하는 알고리즘이다. 의사결정나무, 랜덤포레스트, 서포트벡터머신, 인공신경망 등의 알고리즘이 이에 속한다. 기계학습 알고리즘 중 하나인 인공신경망에서 발전한 딥러닝은 신경망의 층을 더 깊게 쌓아올려 훨씬 복잡하고 추상화된 패턴을 이해하고 학습할 수 있도록 설계된 알고리즘이라고 할 수 있다.



[그림] 인공신경망과 딥러닝의 학습 비교²⁶⁾

딥 러닝은 그동안 장애물로 여겨져왔던 문제들, 즉 비선형문제, 다층 신경망에서의 효과적인 학습모델, 역전파 시 사라지는 경사, 다층 신경망에서의 수렴의 어려움, 컴퓨터 하드웨어의 연산능력 한계, 학습데이터로 사용 가능한 디지털데이터의 부족 등이 기술의 발전에 힘입어 해결되어나가면서 최근 인공지능 분야에서 가장 전망있는 분야로 평가받고 있다.²⁷⁾

Bishop C. M.에 따르면 인공신경망을 하나의 은닉 계층만 가지고도 적절하게 디자인하고 연결강도를 결정하면 어떠한 함수라도 근사적으로 표현할 수 있다고 이미 알려져 있다.²⁸⁾ 하지만 복잡한 데이터의 경우 하나의 층에서 노드의 개수를 증가시키는 방법보다는 은닉 계층을 쌓아 올리는 방법 쪽이 더 다양한 방법으로 모델링이 가능하다는 이점이 있다. 또한 구글의 Ray Kurzweil²⁹⁾이나 MIT의 Tomaso Poggio³⁰⁾ 교수 등 다양한 학자들은 딥러닝이 인간의 뇌신경 구조를 모방하여 형성된 알고리즘이므로 다수의 계층적 모델은 인간수준의 지능을 위해 필수적이라고 말하고 있다.

하지만 딥러닝은 기존의 존재하는 학습데이터에만 의존한다는 단점이 있다. 양질의 학습데이터가 대량으로 활용가능한 경우에만 적용이 가능하므로 기존과 다른 유형의 데이터가 입력되는 경우 결과의 정확

도가 떨어지게 된다. 또한 학습데이터를 반복 학습하는 과정에서 많은 경우 모델을 학습데이터에 지나치게 최적화시키는 과적합(Overfitting) 문제가 발생한다.

딥러닝 모델의 장점과 단점을 정리하면 다음과 같다.

장점	<ul style="list-style-type: none"> - 학습시킬 특징 표현을 고민할 필요가 없음 - 일반적으로 사람이 만든 모델보다 좋은 성능을 가짐 - 고도의 프로그래밍 능력이나 수학적 지식을 요구하지 않음 - 오픈소스 알고리즘이 풍부하여 비용과 기간이 절약됨
단점	<ul style="list-style-type: none"> - 학습 데이터와 다른 새로운 데이터에 적용이 어려움 - 학습 데이터 확보가 어려움 - 과적합 문제가 발생하기 쉬움 - 생성된 딥러닝 모델은 사람이 해석 및 개선하기 어려움

[표] 딥러닝의 장점과 단점³¹⁾

2. 학습유형

데이터를 이용하여 컴퓨터를 학습시키는 방법은 크게 지도학습(Supervised Learning), 비지도학습(Unsupervised Learning), 강화학습(Reinforcement Learning)으로 분류한다. 간혹 강화학습의 경우 학습 중 피드백을 받는 구조때문에 지도학습으로 분류하는 경우도 있으나 지도학습과는 의사결정구조가 다르기 때문에 여기서는 따로 분류하기로 한다.

가. 지도학습(Supervised Learning)

지도학습이란 결과값이 레이블 처리된 대량의 학습데이터로부터

26) 류성일, “4차 산업혁명을 이끄는 인공지능 딥 러닝을 중심으로”. kt BigData Project-TF. 2017.4.

27) 김의중, “알고리즘으로 배우는 인공지능 머신러닝 딥러닝 입문”, 위키북스.

28) Bishop C. M., “Neural Networks for Pattern Recognition”, Oxford University Press

29) Poggio T., Riesenhuber M., “Hierarchical models of object recognition in cortex”, Nature Neuroscience, Vol. 2, No. 11, pp. 1019-1025(1999)

30) Kurzweil R., “How to Create a Mind: The Secret of Human Thought Revealed”, Penguin Books(2012)

31) 안명호 외, “머신러닝을 이용한 알고리즘 트레이딩 시스템 개발”, 2016, 채구성

내재된 함수를 유추할 수 있는 기계학습 방법이다. 학습이 끝난 모델은 새로운 데이터가 주어졌을 때 유추해 낸 함수를 적용하여 새로운 데이터의 레이블 값을 추측할 수 있다. 학습데이터가 잘 분류되어 있을 경우 매우 효율적이기 때문에 회귀분석, 서포트벡터머신, 베イズ분류, 신경망 등 기계학습 대부분의 알고리즘이 지도학습에 속한다. 하지만 현실에 존재하는 대부분 데이터들은 레이블이 존재하지 않는 것이 일반적이기 때문에 지도학습을 위해서는 별도의 레이블 작업이 필요하다는 단점이 있다. 본 논문에서 사용할 학습데이터는 감리결과라는 레이블이 존재하므로 지도학습 방법을 사용하는 것이 가장 효율적인 실험방법이라고 판단된다.

지도학습으로 생성된 모델은 정확도 평가를 통해 신경망의 변수들을 최적화하여 모델을 개선시켜 나갈 수 있다. 정확한 평가를 위해서는 딥러닝 모델이 얼마나 잘 학습되어있는지 평가할 기준이 필요한데 일반적으로 정확한 평가를 위해 학습데이터를 훈련데이터(Training Set), 검증데이터(Validation Set), 테스트데이터(Test Set)로 나눈 다음 교차 검증을 시행하여 모델의 정확도(Accuracy), 정밀도(Precision)와 재현율(Recall)을 측정한다.

정확도, 정밀도와 재현율은 다음과 같이 정의할 수 있다.

$$\text{정확도 : Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{정밀도 : Precision} = \frac{TP}{TP + FP}$$

$$\text{재현율 : Recall} = \frac{TP}{TP + FN}$$

구분		추론	
		Positive(1)	Negative(0)
실제	True(1)	TP (true positive)	FN (false negative)
	False(0)	FP (false positive)	TN (true negative)

[표] Confusion Matrix

정확도는 ‘참’과 ‘거짓’을 추론 결과가 실제 데이터와 정확하게 맞는 비율을 의미하고 정밀도는 ‘참’이라고 추론된 결과 중 실제 ‘참’인 데이터의 비율을 의미하며 재현율은 실제 ‘참’인 데이터 중 추론 결과 ‘참’이 나온 결과의 비율을 의미한다.

$$F\text{-Score} = \frac{Precision \times Recall}{Precision + Recall} \times 2$$

일반적으로 이진분류에서 Confusion Matrix 평가방법이 많이 사용되는 이유는 데이터가 편향되어 있는 경우가 많기 때문이며 따라서 데이터 자체에 특정 성향이 많을 경우 조화평균을 이용하고 있다. F-Score는 정밀도와 재현율의 조화평균을 계산하여 데이터의 비율 자체가 편향되어 있을 경우에도 모델의 추론능력을 신뢰성있게 평가할 수 있는 지표이다. 본 실험에서는 정확도, 정밀도, 재현율과 함께 F-Score를 함께 측정하고자 한다.

나. 비지도학습(Unsupervised Learning)

비지도학습이란 지도학습과 달리 레이블이 존재하지 않는 데이터를 분류하는 과정을 학습하는 방법이다. 주어진 데이터 세트를 동일한 특성을 가진 그룹으로 분류하는 데 그 목적이 있으며 대표적인 비지도학습 모델로는 군집(Clustering) 모델이 있다. 레이블이 없는

데이터 집합으로부터 변수들의 요약 정보를 추출, 연관 패턴을 분석하여 각 데이터 집합이 가지고 특성을 추론할 수 있다. 대표적인 비지도학습 알고리즘으로는 k-means 알고리즘, k-medoids 클러스터링, DBSCAN 클러스터링, 계층적 군집 모델 등이 있다.

자연계에서 존재하는 대부분의 데이터들은 레이블이 없는 경우가 일반적이기 때문에 인터넷 등에서 수집한 원시 데이터들을 적용하기에 적합한 반면 지도학습에 비해 평균적으로 효율성이 떨어지는 학습방법이다.

다. 강화학습(Reinforcement Learning)

강화학습이란 컴퓨터가 일정한 규칙이 설정된 환경 안에서 상황에 맞는 적절한 행동을 할 경우 보상이나 페널티를 획득하는 과정을 반복하면서 최선의 결과를 얻을 수 있는 과정을 학습하는 방법이다. 레이블 처리된 학습데이터가 필요하지 않다는 점, 페널티 행위를 명시적으로 수정하도록 지시하지 않는다는 점에서 지도학습과 다르다.

강화학습은 이미 알고 있는 규칙을 바탕으로 반복적으로 보상과 페널티를 받으며 미지의 영역을 탐험하는 학습방법이라고 할 수 있다. 현재 기계학습 분야에서 가장 전도유망한 분야로 자율주행 자동차나 드론, 로봇틱스 등의 분야에서 지속적으로 연구되고 있는 분야이다.

3. 학습데이터

기계학습에서 필수적인 요소 중 하나가 양질의 학습데이터이다. 설

계한 신경망의 추론능력을 훈련시키기 위해서는 대량의 학습데이터가 필요하며 지도학습의 경우 레이블이 잘 분류되어 있어야 한다. 흔히 말하는 빅데이터 세상인 인터넷의 방대한 데이터 속에서도 이러한 까다로운 조건이 갖춰진 데이터는 흔하지 않으며 대부분의 비정형데이터들은 레이블이 존재하지 않아 지도학습이 어려운 문제점이 있다.

학습데이터를 훈련시키고 정확도를 측정하여 개선시키기 위해서는 데이터집합을 훈련데이터(Training Set), 검증데이터(Validation Set), 테스트데이터(Test Set)로 분류할 필요가 있다.

Training Set	Validation Set	Testing Set
--------------	----------------	-------------


[그림] 학습데이터 분류

훈련데이터는 실제 모델이 반복학습할 데이터 집합이며 이 데이터들에 의해 신경망 노드들 각각의 가중치(weight)와 편향(Bias) 값이 결정된다. 검증데이터는 학습이 완료된 모델을 개선시키기 위하여 사용하는 모의평가용 데이터라고 할 수 있다. 테스트데이터는 오로지 완성된 신경망 모델의 정확성 평가만을 위한 데이터로 검증데이터를 사용하지 않고 테스트데이터로만 모델을 평가할 경우 테스트데이터에 확증편향된 모델이 나올 가능성이 있으므로 검증데이터와 테스트데이터를 미리 나누어 평가하기로 하였다.

가. 학습데이터 선정

본 논문의 실험에서 신경망모델이 학습할 데이터는 금융감독원에서 공시하고 있는 회계감리결과제제결과³²⁾ 및 전자공시시스템³³⁾에

서 제공하고 있는 공시서류 중 ‘벌금등의 부과’ 보고서 항목에서 국세청 세무조사 결과 법인세 부과된 사례를 수집, 코드화하여 레이블 데이터로 사용하였다. 학습 변수 데이터로는 해당 기업의 재무제표(재무상태표와 손익계산서)로 전자공시시스템에서 제공하는 사업보고서 및 감사보고서 상 계정과목 데이터를 수집하여 사용하였다.



[그림] 학습데이터 구성 예시

최종적으로 수집 후 학습데이터로 구성한 재무제표 및 감리 결과 데이터는 1,377건으로 그 중 학습데이터의 주요 변수로 사용된 재무제표의 계정과목 170개의 목록은 다음과 같다. 재무제표 상 계정항목은 대부분 유사하나 일반적인지 않은 계정과목이 사용되고 있을 경우 기타 항목으로 처리하였으며 자산의 감가상각누계액은 해당 자산 계정에서 차감하는 방식을 적용하였다.

현금및현금성자산	어업권	합병차익	임차료	투자자산처분손실
단기예금	차차권	재평가적립금	접대비	유무형자산처분손실
유가증권	창발비	기타자본잉여금	감가상각비	기부금
매출채권	개발비	주식할인발행차금	무형_이연자산상각비	사채상환손실
단기대여금	사용수익기부자산가액	배당건설이자	세금과공과	보상비_건설업
미수금	개입비	자기주식	광고선전비	법인세추납액
선급금	사채발행비	미교부주식매당금	차량유지비	준비금등전입액
이연법인세자산	기타_무형	기타_자본조정	연구비	전기오류수정손실
기타_당좌	장기매출채권	매도가능증권평가손익	경상개발비	채해손실
상품	장기미수금	해외사업환산손익	대손상각비	법인세비용
제품	장기선급금	자본법자본변동	미분양주택관리비	
반제품	보증금	파생상품평가손익	수주비	
재공품	이연법인세자산	기타_기타포괄	기타판매비와관련비	
원재료_원자재	기타_비유동	이익준비금	이자수익	
가설재	매입채무	기업합권화적립금	배당금수익	
저장품	단기차입금	채무구조개선적립금	임대료	
미착상품_미착재료	미지급법인세	조특법상준비금	유가증권처분이익	
완성주택	미지급배당금	기타임의적립금	유가증권평가이익	
미완성주택	선수금	미처분이익잉여금	외환차익	
용지_건설업	유동성장기부채	매출액	외화환산이익	
미성공사	공사손실충당부채	상품매출	지분법이익	
기타_재고	수선충당부채	제품매출	장투증권손상차손환입	
장기예금	이연법인세부채_유동	공사수입	투자자산처분이익	
장기투자증권	기타_유동부채	운송수입	유무형자산처분이익	
지분법적용투자주식	사채	부동산임대수입	사채상환이익	
장기대여금	전환사채등신종사채	분양수입	법인세환급액	
투자부동산	장기차입금	기타매출	충당금_준비금환입	
기타	장기성매입채무	기초재고액	전기오류수정이익	
토지	퇴직급여충당부채	당기매입원가	자산수증이익	
건물	단체퇴직급여충당부채	기말재고액	채무연계이익	
구축물	장기제품보증충당부채	타계정대채액	보험차익	
기계장치	기타충당부채	기초재고액_상품외	이자비용	
선박_항공기	제준비금	당기충원가_명세발행	기타대손상각비	
건설용장비	이연법인세부채_비유동	기말재고액_상품외	유가증권처분손실	
차량운반구	장기공사선수금	타계정대채액_상품외	유가증권평가손실	
건설중인자산	기타_비유동부채	급여	재고자산감소손실	
기타_유형	보통주자본금	퇴직급여	외환차손	
영업권	우선주자본금	보험료	외화환산손실	
산업재산권	주식발행초과금	복리후생비	지분법손실	
광업권	감가차익	여비교통비	장기투자증권손상차손	

[표] 사용된 학습데이터 변수 목록

32) <http://acct.fss.or.kr/fss/acc>, 금융감독원 회계포탈.
 33) <http://dart.fss.or.kr/>, 금융감독원 전자공시시스템.

나. 데이터 정규화

다양한 범위의 값으로 이루어진 학습데이터를 동일한 모델에 적용하기 위해서는 전체 데이터의 범위를 한정하거나 분포도를 유사하게 만드는 작업이 필요한데 이를 데이터 정규화(Normalization)라고 한다. 일반적으로 기계학습 전처리 과정에서 필요한 과정으로 학습 데이터를 정규화함으로써 특이값이나 이상수치를 미리 제거하거나 편차를 없애 모델의 학습 및 추론 능력을 개선시키는 것을 목적으로 한다. 학습데이터를 정규화하는 방법에는 표준화(standardization)와 정규화(normalization) 등이 있다.

데이터 표준화란 각 변수값들이 평균을 기준으로 얼마나 멀리 떨어져 있는지를 표현하는 값으로 변환하는 작업을 말한다. 값의 스케일이 다른 변수들로 이루어진 학습데이터에서 이 스케일 차이를 없애주는 효과가 있다. 각 변수들의 값에서 평균값을 뺀 후 표준편차로 나누어 준 값으로 이는 제로 평균으로부터 각 변수들의 분산을 나타내는 수치이며 그 공식은 다음과 같다.

$$x_n = \frac{x - \mu}{\sigma}$$

[그림] 데이터 표준화(standardization)

데이터 정규화란 변수 값들의 범위를 0과 1 사이로 축소하여 데이터 분포를 일정한 범위로 조정하는 작업을 말한다. 숫자를 가진 범위 값에만 가능한 방법이며 범주형 데이터를 정규화하는 것은 불가능하다. 각 변수들의 값에서 최소값을 뺀 다음 최대값과 최소값이

차이로 나누어준 값으로 그 공식은 다음과 같다

$$x_n = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

[그림] 데이터 정규화(normalization)

본 논문의 실험에서는 데이터 정규화의 방법으로 재무제표의 데이터를 학습데이터로 변환하여 사용함으로써 기업 간 매출규모의 차이에 의한 데이터들의 편차를 최대한 줄이기 위해 노력하였다.

다. 레이블 분류

본 논문에서 실험할 모델은 재무제표 데이터로 회계부정을 탐지할 수 있는 추론능력을 갖추는 것이 최우선 목적이므로 감리결과 분류 중 재무제표 데이터와 연관성이 있는 당기손익, 잉여금, 자기자본 등에 영향을 미치는 사항(A)과 자산, 부채 과대 계상(B)에 해당하는 사례는 True(1) 값을 할당하고 이외 주식 미기재(C), 계정과목의 분류 오류 등(D), 회계기준외의 법규 위반사항(E), 기타 사업년도 사례는 False(0) 값을 할당하였다.

최종적으로 True로 레이블 인코딩된 사례 674건과 False로 레이블 인코딩된 사례 703건, 즉 학습데이터로 1,377건의 재무제표 및 감리결과 데이터를 사용하였다. 레이블 간 학습데이터 개수의 차이가 큰 경우 특정 레이블로 편향된 정확도가 나올 확률이 크기 때문에 미리 레이블 별 학습데이터 개수를 비슷한 수준으로 맞추고 실험을 진행하였다.

4. 모델 학습 및 평가

본 소절에서는 준비된 학습데이터 세트로 다양한 기계학습 알고리즘을 적용해보고 그 결과를 바탕으로 하여 최종적으로 딥 러닝 모델을 구현하고 평가하고자 하였다.

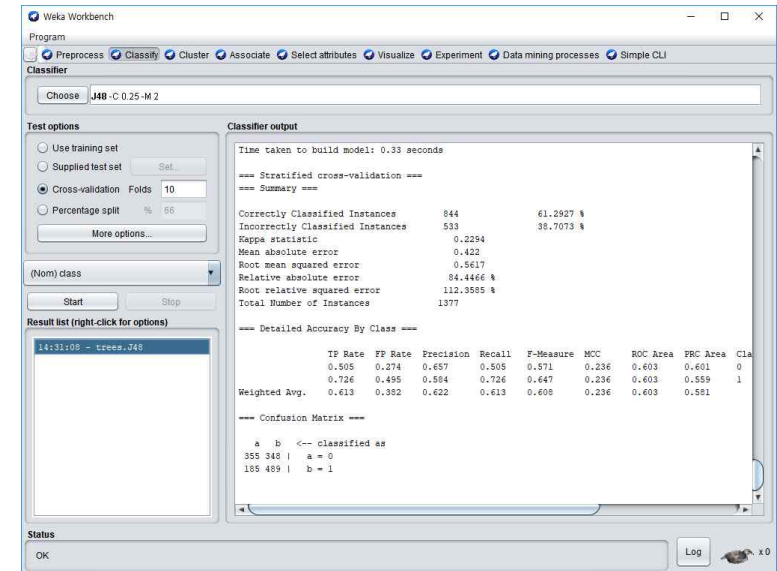
가. 알고리즘 실험

준비된 학습데이터로 딥러닝 모델을 생성하기 앞서 앞장에서 살펴본 다양한 기계학습 알고리즘을 적용하여 데이터에 맞는 최적의 알고리즘이 어떤 종류인지 탐색해보고자 하였다. 추가로 이 과정을 통하여 의사결정나무, 랜덤포레스트, 서포트벡터머신, 멀티퍼셉트론 알고리즘을 적용해보고 재무제표 데이터가 과연 다수의 은닉층 신경망 모델이 필요할 만큼 복잡한 데이터인지 여부도 파악하고자 하였다. 이 실험에서는 앞 장에서 설명한 Weka 프로그램을 이용하였다.

(1) 의사결정나무 알고리즘 실험

아래는 Weka에서 J48이라는 이름으로 제공되고 있는 의사결정나무 알고리즘을 사용하여 학습데이터를 적용해본 결과이다. 여기서는 수동으로 훈련데이터를 분류하지 않고 Cross-validation 옵션을 사용하여 프로그램이 자동으로 학습데이터를 일정 비율로 분류하여 학습 후 검증하는 방법을 사용하였다. Cross-validation는 교차검증 옵션으로 학습데이터를 여러 학습/테스트 데이터로 나눈 다음 복수의 학습 검증을 실시한 후 평균 성능과 평균 분산을 구해주는 옵션이다. 학습데이터와 테스트데이터를 나누는 기준인 Percentage split

옵션값은 66%를 적용하였다. 여러차례 반복 실험한 결과에서 평균적으로 보여지는 결과는 다음 그림과 같다.



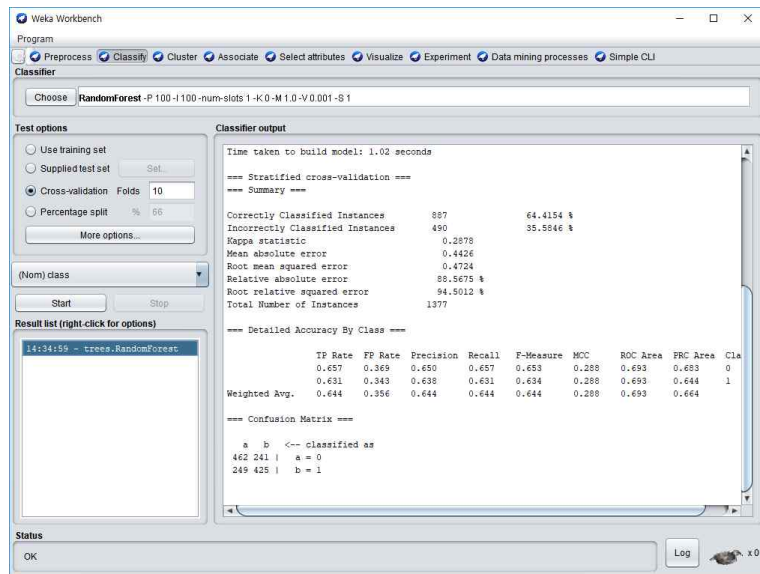
[그림] 의사결정나무 알고리즘 적용 결과

구분	정확도	정밀도	재현율	F-Score
측정값	61.2%	62.2%	61.3%	60.8%

그림에서 확인할 수 있듯 정확도, 정밀도, 재현율, F-Score 모두 60%를 조금 넘는 결과를 보여주고 있다. 레이블이 참과 거짓, 두 가지 분류인 학습데이터에서 이 정도 레벨의 정확도로 유의미한 추천 모델을 만들기는 어려우며 반복 실험에서도 결과는 크게 다르지 않아 다른 기계학습 알고리즘을 계속하여 실험하고자 하였다.

(2) 랜덤포레스트 알고리즘 실험

다음은 Weka에서 제공하는 RandomForest 알고리즘을 적용하여 테스트한 결과이다. 랜덤포레스트는 학습데이터를 무작위로 샘플링하여 다수의 결정나무를 만든 후 그 결과를 취합, 다수결로 최종 결과를 추론하는 알고리즘으로 앙상블 학습의 일종이라 할 수 있다. 의사결정나무 알고리즘 실험과 마찬가지로 Cross-validation 옵션을 사용하였고 Percentage split 옵션값은 66%를 적용하였다.



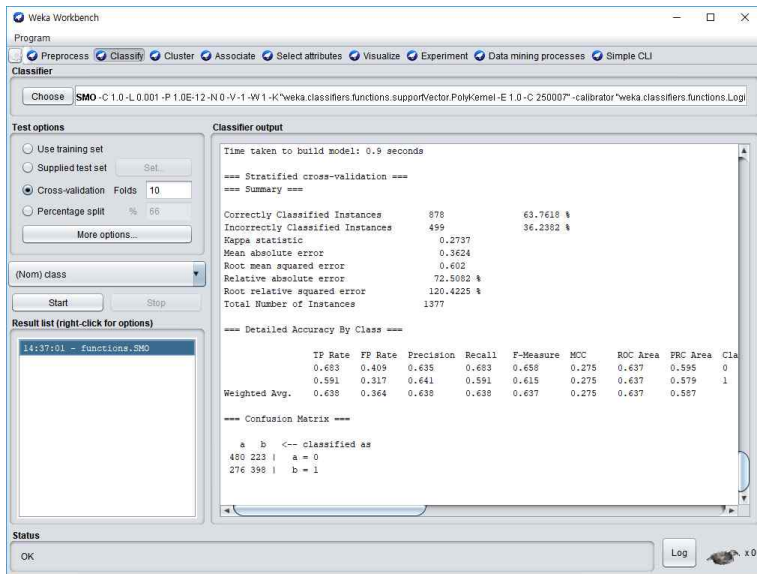
[그림] 랜덤포레스트 알고리즘 적용 결과

구분	정확도	정밀도	재현율	F-Score
측정값	64.4%	64.4%	64.4%	64.4%

의사결정나무 알고리즘과 비교할 때 일정한 수준으로 개선된 정확도, 정밀도, 재현율, F-Score 값을 보여준다. 일반적으로 의사결정나무 알고리즘에 비해 더 많은 트리를 사용하기 때문에 정확도는 더 높아지나 그만큼 리소스가 많이 소요되는 편이다. 그러나 변수와 레이블 간 긴밀한 연관관계가 존재한다고 판단하기 위해서는 좀 더 개선된 추론 능력이 필요할 것으로 보인다.

(3) SVM(Support Vector Machines) 알고리즘 실험

신경망모델이 기울기소실 문제를 해결하여 정확도를 개선하기 전까지 가장 많이 사용되어왔던 SVM 알고리즘은 Weka에서 SMO Classify라는 이름으로 제공되고 있다. 일반적으로 일반화 오차를 줄일 수 있고 모델이 과적합 문제가 잘 발생하지 않는다는 장점이 있어 학습할 데이터가 고차원으로 구성되어 있거나 데이터가 희소할 경우 효율적이라고 알려져 있다. 다음은 Weka에서 제공하는 SMO 알고리즘을 적용하여 테스트한 결과이다. 중요 매개변수인 커널함수로는 Poly-kernel을 적용하는 경우가 가장 결과가 좋았으며 상기 실험들과 마찬가지로 Cross-validation 옵션을 사용하였고 Percentage split 옵션값은 66%를 적용하였다.



[그림] SVM 알고리즘 적용 결과

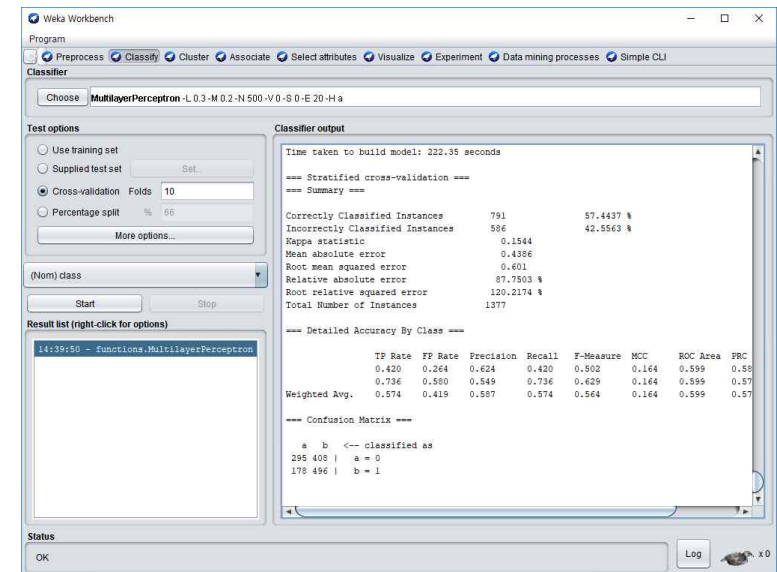
구분	정확도	정밀도	재현율	F-Score
측정값	63.7%	63.8%	63.8%	63.7%

의사결정나무 알고리즘의 경우보다는 높은 정확도이나 랜덤포레스트 알고리즘을 사용했을 경우에 비하면 조금 낮은 63% 수준의 정확도, 정밀도, 재현율, F-Score 값을 보여준다.

(4) 멀티 레이어 퍼셉트론(MLP) 알고리즘 실험

멀티 레이어 퍼셉트론(Multi Layer Perceptron) 알고리즘은 입력층과 출력층 사이에 하나 이상의 은닉층이 존재하는 신경망 모델이다. Weka에서 지원되는 인공신경망 알고리즘으로 본격적으로 기계학습

프레임워크를 사용하기 전 간단하게 신경망모델을 사용하여 지도학습 결과를 확인해 볼 수 있다. 위와 동일한 학습데이터를 사용하여 멀티 레이어 퍼셉트론 알고리즘을 적용한 결과값은 다음과 같다. 역시 Cross-validation 옵션을 사용하였고 Percentage split 옵션값은 66%을 적용하였다.



[그림] Multi Layer Perceptron 알고리즘 적용 결과

구분	정확도	정밀도	재현율	F-Score
측정값	57.4%	58.7%	57.4%	56.4%

의사결정나무 및 랜덤포레스트 알고리즘을 사용했을 경우보다 더 낮은 수치의 정확도, 정밀도, 재현율, F-Score 값을 보여준다. 하지만 신경망모델의 경우 은닉층과 노드, 활성화함수, 반복횟수 등의

변수 설정과 신경망을 어떻게 설계하느냐에 따라 결과값의 편차가 크기 때문에 이후부터는 신경망모델을 다양하게 실험할 수 있는 텐서플로우 프레임워크를 사용하여 보다 자세한 인공신경망 모델 실험을 진행하고자 하였다.

나. 딥러닝 모델


Weka 프로그램을 사용하여 기존 기계학습 알고리즘에 학습데이터를 적용한 실험에서 유의미한 추론능력을 도출하지 못함에 따라 신경망모델을 좀더 심층적으로 설계 및 구현하여 정확도를 개선해보고자 시도하였다. 이 과정에서 고려해야 할 요소에는 활성화함수 선택, 과적합문제 완화, 신경망의 깊이 및 노드의 수준 등이 있다.

(1) 활성화함수(Activation Function)

신경망모델에서 각 노드에 입력되는 값들을 모아 출력값으로 변환해주는 함수를 활성화함수(activation function)라고 한다. 활성화함수는 특정 조건을 통하여 출력값이 어디에 속하는 지 분류해주는 기능을 하며 이 함수의 사용 여부는 초창기 퍼셉트론모델과 신경망모델의 차이점이기도 하다. 다양한 활성화함수 중에서 주로 이용되었던 것은 Sigmoid 함수로 계단형식의 함수를 미분이 가능하도록 곡선화하여 어떠한 값이 입력되더라도 0과 1로 값을 출력할 수 있도록 해 준다.

신경망모델은 기본적으로 출력층으로부터 은닉층들을 거슬러올라가면 각 층의 노드들의 가중치를 수정해나가는 오차 역전파 기법을 사용한다. 이 노드들의 가중치 값을 수정하기 위해서는 미분 값, 즉

기울기가 필요한데 은닉층의 수가 늘어날수록 기울기값이 줄어들어 0으로 수렴하는 이른바 기울기 소실(vanishing gradient) 문제가 발생한다. 이는 신경망모델의 공통된 문제이며 Sigmoid 함수 역시 다수의 은닉층으로 설계된 모델의 경우 기울기 하강(Gradient Descent)이 진행될수록 error 값이 소멸되어버리는 문제가 존재한다. 이는 Sigmoid 함수의 특성 상 극한으로 갈수록 기울기 값이 작아져서 가중치가 업데이트되지 않기 때문이다.



[그림] Sigmoid 함수와 ReLU 함수 비교³⁴⁾


그에 반해 ReLU(Rectified Linear Unit) 함수의 경우에는 기울기가 0이거나 1일 때 error가 100%로 전파되기 때문에 Sigmoid 함수에 비해 기울기 하강 문제가 나타날 소지가 작다. 또한 ReLU 함수는 Sigmoid 함수처럼 0과 1 사이의 값으로 한정되지 않고 제한이 없어 학습모델이 좀 더 다양한 표현력을 가질 수 있는 장점이 있다. 성능 관점에서도 모든 노드들의 출력값을 계산해야 하는 Sigmoid 함수와 달리 필요없는 연산량을 줄일 수 있다는 점에서 유리하며 이러한 점은 딥러닝 모델의 일반화(Regularization)에도 도움이 된다. 따라서 최근의 신경망모델 연구에서는 ReLU 함수를 주로 사용하는 경향이 있으며 이에 따라 본 논문의 실험에서도 ReLU 함수를 주된

34) <https://towardsdatascience.com/activation-functions-neural-networks-1cbd9f8d91d6>

활성화함수로 사용하기로 하였다.

(2) 드롭아웃(dropout)

드롭아웃이란 매 학습마다 신경망의 노드를 임의로 선택하여 제거한 뒤 반복학습하는 기법이다. 개별 학습단계마다 계층별, 데이터별로 랜덤하게 노드를 선택하여 제거하며 전체 학습이 끝난 후 제거했던 노드들을 복원시킨다. 그 후 개별 노드들의 가중치 값에 노드 제거 시 확률값을 곱하여 드롭아웃된 노드로 학습한 결과를 보상한다. 드롭아웃 기법으로 과적합 문제를 어느정도 완화시킬 수 있으며 모델의 안전성과 정확도 향상에 도움이 된다고 한다.³⁵⁾ 또한 특정 노이즈가 전체 노드에 파생되는 상호작용 문제도 해소할 수 있다. 다만 반대로 소수의 유의미한 특성을 모델에 반영하기는 그만큼 어려워진다.



[그림] DROP OUT의 개념³⁶⁾

본 실험에서는 과적합 문제를 방지하기 위하여 드롭아웃 변수를

35) P. Baldi, P. J. Sadowski, "Understanding dropout", Advances in Neural Information Processing Systems(NIPS), pp. 2814-2822(2013)

36) <https://www.analyticsvidhya.com/blog/2017/05/25-must-know-terms-concepts-for-beginners-in-deep-learning/dropout-2/>

기본 50% 수준부터 적용하였으며 결과값을 보면서 변경하며 실험을 진행하고자 하였다. 실제 신경망의 은닉층과 노드를 구성하기 위한 Python 코드 상에서는 contrib.learn.DNNClassifier의 dropout 옵션을 사용하여 변수를 설정하였으며 결과값을 참고하여 모델의 추론 정확도를 개선하고자 노력하였다.

(3) 신경망모델 설계

신경망모델을 구성하는 물리적 요소는 은닉층과 노드인데 일반적으로 학습데이터에 적합한 은닉층과 노드의 개수를 알아낼 수 있는 공식은 존재하지 않는다. 따라서 학습할 데이터의 특성에 맞는 신경망을 설계하기 위해서는 학습 결과의 지속적인 피드백이 중요하다고 할 수 있다. 본 논문의 실험에서는 복수의 모델을 설계하고 정확도를 비교함으로써 학습데이터에 가장 알맞은 은닉층과 노드의 개수를 찾기 위해 노력하였다.

전 편에서 기술한 바와 같이 모델의 정확도를 측정하기 위하여 우선 학습데이터에서 검증데이터와 테스트데이터를 분리하여 학습에서 제외시키는 과정이 필요하다. 학습데이터가 충분한 경우 검증데이터 및 테스트데이터의 비중을 높이는 것이 모델의 신뢰도를 높일 수 있는 방법이나 본 논문에서는 사용할 수 있는 학습데이터의 개수가 1,377건으로 한정되어있으므로 각 데이터를 6:2:2의 비율로 나누어 학습 및 검증, 테스트에 사용하기로 한다.


Training Set 60%	Validation Set 20%	Testing Set 20%
---------------------	-----------------------	--------------------

[그림] 데이터 분류


학습데이터 1,377건을 상기 비율대로 나누었을때 학습데이터 827건, 검증데이터 275건, 테스트데이터 275건으로 분류할 수 있으며 편향된 결과값이 나오지 않도록 세 데이터집합의 레이블 비율을 일정한 수준으로 균등하게 분류하였다.

모델의 최적화된 은닉층(hidden layer)의 개수는 의사결정의 경계를 정하는 데 중요하며 다음과 같은 사항이 고려되어야 한다. 다층신경망모델의 경우 단층 신경망모델보다 고차원의 패턴을 분류할 수 있지만 학습을 적정한 수준으로 조절하기가 어려우며 층이 깊어질수록 기울기소실 문제가 발생할 확률이 커지게 된다. 또한 각 층의 노드 수가 너무 많으면 네트워크의 일반화가 어려울 뿐만 아니라 학습에 많은 시간이 소요되는 반면 반대로 너무 적으면 복잡한 의사결정 경계를 만들기 힘들어지는 측면이 있다.


최적화된 은닉층과 노드의 개수를 결정할 수 있는 알려진 법칙은 현재 존재하지 않으며 반복 실험을 통해 데이터에 최적화된 신경망 모델을 찾아 나가는 과정을 거칠 수 밖에 없다. 일반적으로 입력 변수 갯수의 절반부터 시작하여 노드 개수를 결정하고 은닉층의 수를 늘려가는 방법이 많이 사용된다. 따라서 본 실험에서는 노드수가 각 80개, 40개, 20개로 구성된 3층의 은닉망을 가진 신경망 모델을 먼저 설계하고 결과값을 피드백받아 모델을 계속 재구성해나가기로 하였다. 아래는 설계된 신경망모델을 10000회까지 100회 단위로 반복학습시킨 결과로 텐서플로우 프레임워크에서 제공하는 텐서보드 기능을 이용하여 그래프로 시각화한 주요 학습곡선들이다.




[그림] 모델의 정확도 곡선



[그림] 모델의 정밀도 곡선



[그림] 모델의 재현율 곡선



[그림] 모델의 학습비용 곡선

텐서플로우는 텐서보드를 통하여 신경망모델의 학습곡선과 비용 등 주요 수치들을 그래프로 보여주는 기능을 제공한다. 위 그림은 학습된 신경망의 정확도 관련 그래프이며 생성된 모델이 학습데이터를 얼마나 잘 레이블에 맞게 잘 분류하는지 성능을 나타낸다. 그러나 정확도 그래프를 보면 이미 학습했던 데이터를 재분류하여 평가했기 때문에 학습데이터에 과적합된 상태임을 알 수 있다. 예를 들어 10000번 반복학습을 한 신경망모델의 경우 학습데이터를 약 98% 수준으로 재분류하는 높은 추론능력을 보여주고 있으나 학습하지 않은 새로운 데이터를 입력받을 경우의 정확도를 보장하는 것은 아니다. 따라서 미리 별도 분류해놓은 검증데이터와 테스트데이터를 사용하여 생성된 모델을 객관적으로 평가할 필요가 있으며 테스트 결과는 다음과 같다.

은닉층 구조	반복학습 횟수	학습 정확도	실제 정확도
80-40-20	1,000	68.3	65.8
	2,000	74.7	64.0
	3,000	82.8	64.0
	4,000	89.4	64.0
	5,000	93.8	65.0
	6,000	93.4	64.0
	7,000	96.1	65.4
	8,000	98.1	63.6
	9,000	97.4	64.7
	10,000	98.4	64.3

[표] 모델의 실제 정확도 측정 결과

표에서 나타난 바와 같이 학습에 사용되지 않은 데이터로 추론 능력을 검증한 결과는 앞장에서 랜덤포레스트 알고리즘을 이용하여 학습한 정확도와 유사한 수준으로 측정되었다. 따라서 본 논문에서

는 은닉층과 노드의 개수를 다양하게 적용하여 다수의 모델을 설계, 테스트하여 학습데이터에 최적화된 신경망 네트워크 구조를 찾고자 시도하였다. 각 모델들은 100번의 간격으로 계속 반복학습시켰으며 검증데이터로 최적화된 학습횟수를 결정한 다음 테스트데이터를 사용하여 실제 정확도를 측정하는 방식을 사용하였다. 이 과정에서 설계 및 테스트에 사용된 신경망 모델들은 다음과 같으며 모델별로 가장 높은 실제 정확도를 보여주는 결과는 다음과 같이 측정되었다.

은닉층 구조	반복학습 횟수	학습 정확도	실제 정확도
80	800	66.6	65.1
80-40	2,200	71.7	66.2
80-40-20	4,700	89.5	65.1
80-40-20-10	1,200	68.4	66.9
80-40-20-10-5	800	65.5	68.4
170	600	66.7	65.1
170-90	2,100	80.2	65.8
170-90-45	1,100	71.6	65.8
170-90-45-20	1,300	70.1	65.5
170-90-45-20-10	1,200	69.9	67.2
120	1,500	68.6	65.1
120-60	800	67.8	65.5
120-60-30	1700	73.5	66.2
120-60-30-15	900	71.9	67.6
120-60-30-15-8	2,500	74.1	65.1

[표] 모델의 실제 정확도 측정 결과

학습하지 않은 테스트데이터를 가장 잘 추론해 낸 모델은 80, 40, 20, 10, 5개의 노드를 가진 5개 은닉층의 신경망 모델로 실제 정확도가 68.3%로 측정되었으며 그 다음으로 120, 60, 30, 15개의 노드를 가진 4개 은닉층의 신경망 모델이 실제 정확도가 67.6%, 그리고 170, 90, 45, 20, 10개의 노드 구조를 가진 모델이 67.2%의 실제 정

확도를 보여주었다. 실험에 사용된 15개 모델의 실제 정확도의 평균은 66.0% 수준으로 측정되었다.

다. Confusion Matrix 평가

전 장에서 소개한 Confusion Matrix 평가방법을 이용하여 생성된 딥 러닝 모델의 실제 성능을 평가하였으며 이는 학습 후 검증데이터를 사용하여 최적화시킨 모델에 최종적으로 별도 테스트데이터를 적용하여 추론 결과의 정확도를 측정한 값이다. 이 과정에서 학습데이터 및 검증데이터는 모델에 피드백을 주고 있으므로 최종 정확도 평가용으로 사용할 시 편향된 결과를 얻을 우려가 있다. 따라서 당초 학습데이터를 분류하여 평가용으로 구분해놓은 테스트데이터를 입력하여 결과값의 정확도를 측정하면 모델의 실제 정확도를 알 수 있다. 최종적으로 가장 높은 실제 정확도를 보여준 신경망 모델 3건으로부터 측정된 값들은 다음과 같다.

은닉층 구조	정확도	정밀도	재현율	F-score
80-40-20-10-5	68.4	66.4	71.8	68.9
120-60-30-15	67.6	65.9	70.3	68.0
170-90-45-20-10	67.2	66.1	68.1	67.1

[표] 모델의 Confusion Matrix 측정 결과

정밀도, 재현율, F-score 값들이 모두 정확도와 유사한 수준으로 확인되는 바, 실험 결과에 있어 데이터의 편향성은 없다고 판단되며 따라서 각 모델에서 측정된 정확도 수치는 신뢰성이 있는 것으로 보인다.

제5장 결론

1. 연구의 결과

본 논문의 연구에서 재무제표 데이터로부터 감리결과를 추론하기 위하여 신경망 모델을 설계하고 학습을 시켜본 결과 기타 기계학습 알고리즘을 사용하여 학습했을 경우에 비하여 평균 5% 이상 향상된 정확도 값을 얻을 수 있었다. 정확도 수치 뿐만 아니라 정밀도와 재현율, F-score 값들이 모두 일정한 수준을 나타내고 있으므로 이는 데이터가 편향되지 않은 유의미한 수치로 판단된다. 실제로 68.3%의 정확도는 새로운 데이터 3건이 입력되었을 때 2건의 레이블을 추론해내는 수준이므로, 입력 변수와 레이블 사이에 어느정도 느슨한 연관관계가 있음을 보여주고 있다. 즉, 재무제표 데이터로부터 감리결과를 추론하기 위한 모델로 사용하기 위해서는 정확도 부분에서 보완이 필요할 것이나 감리 및 조사 대상을 선정하기 위한 객관적이고 공개적인 사전절차의 보조지표로 사용되기에는 유용한 수준으로 보인다.

2. 연구의 한계 및 향후 과제

본 논문과 관련된 연구는 세 가지 한계점을 가지고 있다. 우선 첫 번째 한계점으로 학습데이터의 편향성 문제가 있다. 공시된 재무제표 데이터와 감리 결과 데이터를 사용했음에도 불구하고 1,377건의 사례만으로는 전체 기업의 실제 회계부정 사례가 얼마만큼 편향되지 않고 균등하게 반영되어 있는지 알 수 없으며 더불어 감리결과 이상이 없다 하더라도 실제 회계부정이 없는 것인지 감리가 잘못

된 것인지 여부는 알 수 없다. 이 문제를 완화하기 위해서는 최대한 많은 학습데이터 확보가 필수적으로 보이며 장기적으로 양질의 학습데이터를 누적시켜나가야 할 것이다.

두 번째 한계점은 학습데이터의 변수로 비재무적 요소가 배제되어 있다는 점이다. 실제 회계부정 사례를 보면 이사회 구성, 경영인의 인적 성향, 해당 기업의 사업 특성 또는 종속회사와의 특수한 관계 등 재무제표 외의 요소가 많이 영향을 미치고 있다는 점을 알 수 있다. 그러나 이런 비재무적 요소는 계량화가 어렵고 누적된 자료가 없어 실제 기계학습 알고리즘에 적용하기 현실적으로 어려운 관계로 본 연구에서는 부득이 재무제표 데이터로 한정하게 되었다. 향후 연구에서는 이러한 비정형 데이터들을 학습할 수 있는 방안도 함께 고려되어야 할 것으로 보인다.

마지막으로 한계점으로 구현된 딥 러닝 모델의 낮은 예측 정확도를 들 수 있다. 본 연구에서 확인된 수준의 정확도는 재무제표의 변수와 감리 결과 간 유의미한 연관성이 추정된다는 정도로 조사대상 선정에 있어 사회적 공감대 형성을 기대하기는 어려운 수준으로 보이며 결국 주 판단기준이 아닌 하나의 보조지표 정도로 인식될 수 밖에 없을 것으로 판단된다. 따라서 앞으로 정확도를 높이기 위해서는 더 많은 학습데이터를 바탕으로 업종별, 상세 부정유형별 등 보다 세분화된 모델을 구성하는 것이 바람직할 것이다.

회계부정을 근절하기 위한 국가와 사회의 노력에도 불구하고 그 사례는 계속 발생하고 있다. 비단 밝혀진 사례 외에 아직도 밝혀지지 않은 사례는 더 많을지도 모르는 일이다. 하지만 이를 방지하기 위한 감리나 조사를 제대로 시행하기 위해서는 엄청난 인력과 사회

적 비용이 투입되어야 할 것이다. 본 논문에서는 공시된 재무제표 데이터를 이용하여 기업의 회계부정을 객관적인 방법으로 예측할 수 있는 방법을 연구함으로써 실제 감리나 조사할 대상을 선정하는데 있어 그 현실적 범위를 줄이는데 도움이 되고자 하는 의도가 있다. 더불어 객관적인 예측모델을 만들 수 있다면 대상 선정과정에서 공정성과 객관성이 담보될 수 있을 것이며 그로 인한 불필요한 사회적 갈등도 해소할 수 있을 것으로 기대한다.

[참고문헌]

1. 이규안, 박대우, 고청심. “과학수사를 위한 디지털 포렌식”. GS 인터비전. 2011.
2. 최영근. “포렌식 부정적발 회계론”. 계명대학교출판부. 2011.
3. 조성원, “회계부정 예측에 관한 연구”. 박사학위논문, 단국대학교, 2007.
4. 금융감독원. “2013년도 감사보고서 감리결과 주요 감리지적사례 및 유의사항”. 2014.
5. 김억, “재무제표상의 이상징후 탐지를 위한 포렌식 어카운팅 기법 연구”, 고려대학교, 2010.
6. 이성원, “재무비율의 위험 징후를 통한 회계부정의 예측에 관한 연구”, 경기대학교, 2007.
7. 오은미, “분기별 재무자료를 활용한 포렌식 어카운팅 기법”, 숭실대학교, 2014.
8. Vapnik, V. 《The nature of statistical learning theory》. New York: Springer-Verlag New York. 2000.
9. Press, William H.; Teukolsky, Saul A.; Vetterling, William T.; Flannery, B. P. 《Numerical Recipes: The Art of Scientific Computing》. New York: Cambridge University Press. 2007.
10. 류성일. “4차 산업혁명을 이끄는 인공지능 딥 러닝을 중심으로”. kt BigData Project-TF. 2017.4.
11. D. C. Cirean, U. Meier, J. Masci, J. Schmidhuber. Multi-Column Deep Neural Network for Traffic Sign Classification. Neural Networks, 2012.
12. D. Cirean, A. Giusti, L. Gambardella, J. Schmidhuber. Deep Neural Networks Segment Neuronal Membranes in Electron Microscopy Images. In Advances in Neural Information Processing Systems (NIPS 2012), Lake Tahoe, 2012.
13. D. C. Cirean, U. Meier, J. Schmidhuber. Multi-column Deep Neural Networks for Image Classification. IEEE Conf. on Computer Vision and Pattern Recognition CVPR 2012.
14. 김의중, “알고리즘으로 배우는 인공지능 머신러닝 딥러닝 입문”, 위키북스.
15. Bishop C. M., “Neural Networks for Pattern Recognition”, Oxford University Press.
16. Poggio T., Riesenhuber M., “Hierarchical models of object recognition in cortex”, Nature Neuroscience, Vol. 2, No. 11, 1999.
17. Kurzweil R., “How to Create a Mind: The Secret of Human Thought Revealed”, Penguin Books, 2012.
18. 안명호 외, “머신러닝을 이용한 알고리즘 트레이딩 시스템 개발”, 2016.
19. P. Baldi, P. J. Sadowski, “Understanding dropout”, Advances in Neural Information Processing Systems(NIPS), 2013.

<참고 웹사이트>

1. www.fsc.go.kr 금융감독위원회
2. www.fss.or.kr 금융감독원
3. www.kicpa.or.kr 한국공인회계사회
4. www.riss4u.net 전자공시시스템
5. www.kasb.or.kr 한국회계기준원
6. www.riss4u.net 한국교육학술정보원의 학술연구정보서비스

Abstract

Master of Science in Digital Forensics
Department of Mathematical Information Science
The Graduate School of Convergence Science and Technology
Seoul National University

Accounting fraud refers to unethical illegal activities in which companies intentionally manipulate a company's financial position in complex and diverse ways, such as overaccumulating sales, reducing spending, falsifying assets, reducing debts, and operating abnormal funds.

In the case of Enron Corp., a representative example of the US, not only has the shareholders and creditors suffered large losses due to the stock price depreciation due to accounting fraud, but also caused many employees who had treasury stocks to suffer tremendous damage due to corporate default. It can be seen that

fraud can have a serious adverse impact not only on the insolvency issue of the company but also on the national economic side as well as on the social side.

Therefore, by studying new forensic accounting techniques that can prevent such accounting fraud, it is possible not only to prevent damage to investors, national institutions and the general public who have direct or indirect interests with the company, but also to prevent socially sound corporate accounting culture. The purpose of this study is to help expand the environment in which sustainable companies can grow through the creation of new businesses.

The purpose of this study is to track the relationship between financial statements and accounting negativity by using the data of the entire financial statements and the guidance learning method using the deep learning algorithm. As a learning material, we utilized the audited intellectual enterprise data published by the Financial Supervisory Service.

In this paper, we propose a forensic accounting method that can detect financial negativity in advance by a machine learning model that learns published financial statements and audit results. First, we propose a method of predicting the results of a new company's financial statements after learning the machine learning model with learning data classified according to the points indicated by the supervision. In order to verify the accuracy of the prediction, we performed a procedure to verify the accuracy of the model trained with separate evaluation data. In addition, we tried to apply various machine learning models such as decision tree, random forest, and support vector machine

to make up for the shortcomings of the deep learning model which depends on the quality of learning data.

Accounting fraud negatively affects not only individual and institutional investors but also society as a whole by manipulating the financial condition of a corporation. Therefore, in order to prevent accounting fraud, related organizations are making efforts to improve relevant laws and regulations, and the level of punishment in violation is gradually increasing. Nevertheless, accounting fraud is still continuing for the purpose of attracting investment or securing funds, and a vicious cycle continues to occur in which financial institutions or investors use misleading financial statements to make corporate judgments. Therefore, it is expected that there will be an increasing need for detection techniques that can quickly predict accounting fraud as data already disclosed before the audits and audits.

Key words : accounting fraud, financial statements, deep running, machine learning, machine learning, forensic accounting