

## 딥러닝 기반 부실기업 예측모형에 관한 연구

조재혁 \*

안은주 \*\*

김성수\*\*\*

### 〈요약〉

부실기업 예측은 회계와 재무 분야에서 중요하게 다루어져 온 연구 주제이다. 특히, 급변하는 기업 환경과 최근 COVID-19 대유행으로 국내의 많은 기업이 기업 부실화로 재무적 어려움에 직면하고 있어 그 연구의 필요성이 더욱 강조되고 있다. 대표적인 관련 연구로는 기업부도 예측이 있지만, 부도기업은 사실상 사업활동을 중단한 기업으로 계속기업 간에 어떠한 기업이 부실 징후를 보이는지를 판단하는 기준으로 부적합하다는 한계점이 존재한다. 본 연구는 부실기업의 범주 중 하나인 한계기업을 그 예측대상으로 선정하였다. 한계기업은 3개년도 연속 이자보상비율이 1 미만인 기업으로, 사업활동을 영위하고 있으나 적정 수준의 이익을 지속적으로 확보하지 못하고 있는 부실기업을 의미한다. 본 연구에서는 한계기업 예측을 위한 방법으로 딥러닝 기법을 활용하였다. 딥러닝은 다양한 분야에서 그 우수성을 인정받아 최근 주목받고 있는 머신러닝 기법의 하나이지만 한계기업 예측을 위한 연구에서는 적용된 바가 없다. 본 연구는 여러 재무비율 변수를 독립변수로 하여 딥러닝 기법 중 RNN과 CNN을 적용하고, 선행연구에서 예측력이 뛰어나다고 보고된 머신러닝 앙상블 모형들과 그 성과를 비교하였다. 2017~2019년의 기업 데이터를 학습용 및 테스트용 데이터로 설정하여 분석한 결과, RNN-LSTM, RNN-GRU, CNN이 재현율(Recall)의 관점에서 우수한 성과를 보이는 것으로 나타났다. 그러므로 딥러닝 모형이 한계기업 예측에서도 널리 사용될 수 있는 분석방법이 될 것으로 기대된다.

**한글 색인어 :** 기업 부실화, 딥러닝 기법, 머신러닝, 앙상블 모형, 한계기업 예측

## 1. 서론

1997년 IMF 외환위기, 2008년 글로벌 금융 위기, 최근의 COVID-19 대유행 등 범세계적인 경제 위기를 초래하는 사건들이 각 국가의 경제에 지대한 악영향을 미치고 있다. 이처럼 경기가 침체되면서 경영 활동을 영위하는 많은 기업이 급격한 외부환경의 변화에 신속하게 대응하지 못하는 사례가 증가하고 있다. 이는 이익 감소 및 손실 누적 등 경영성능이 악화되고, 결국 기업 부실화로 이어져 기업의 생존을 위협하는 상황을 초래하였다. 또한, 기업 부실화는 단순히 해당 기업에만 국한되는 문제가 아닌 기업의 경영자, 종업원, 투자자, 지역 경제 등 기업과 관련된 수많은 이해관계자에게도 부정적인 파급

효과를 일으킨다. 즉, 매출액 감소, 영업활동의 중단, 부실화 관련 제반 비용 발생 등으로 기업 부실화는 이해관계자들에게도 피해를 주기 때문에 다양한 관점에서 그 실무적 중요성을 가진다.

이러한 기업 부실화를 예측하기 위하여 과거부터 많은 연구가 이루어져 왔는데, 대표적인 연구 주제로는 부도기업 예측이 있다. 기업의 부도 가능성을 사전에 파악할 수 있다면 해당 기업의 이해관계자들로 하여금 조기에 기업을 정상화하거나 합리적인 기업 청산을 통해 사회적·경제적 손실을 줄일 수 있다(김진백, 이준섭, 2000, 230; 김성환, 박천식, 전성민, 2011, 100). 기업부도 예측은 전통적인 통계기법들에 기반하여 1960년대부터 본격적으로 연구가 수행되기 시작하였다.

논문제출일 : 2021.01.25

논문심사일 : 2021.02.17

게재확정일 : 2021.02.17

\* 경북대학교 경영학부 박사과정(E-mail: jjg7578@knu.ac.kr) : 제1저자

\*\* 경북대학교 경영학부 박사과정(E-mail: dmswn8808@naver.com) : 공동저자

\*\*\* 경북대학교 경영학부 부교수(E-mail: sungukim@knu.ac.kr) : 교신저자

대표적으로 Altman(1968, 609)은 5가지 재무변수를 이용하여 다중판별분석(Multiple Discriminant Analysis)을 통해 기업의 부도위험을 예측하고자 하였다. 그 외에도 로지스틱 회귀모형(Logistic Regression Model)을 활용한 부도예측 연구(Ohlson, 1980, 130)나 프로비트(Probit) 모형 기반의 부도예측 연구(Zmijewski, 1984, 77) 등 다양한 통계기법들이 적용된 연구들이 수행되었으며 각 연구는 그 나름의 시사점을 제시하였다.

그러나 이러한 기존의 기업부도 예측 연구는 실무적·방법론적인 한계점을 가진다. 먼저 실무적 관점에서 부도기업은 사실상 사업 활동을 중단한 기업이므로, 예측 가능한 기간에 사업 활동을 지속할 것으로 예상되는 계속기업들 사이에서는 어떤 기업이 관리대상이 되는지를 예측하는 판단 기준이 되기 어렵다는 한계점이 존재한다. 이를 극복하기 위해서는 계속기업 중 부실기업으로 볼 수 있는 새로운 기업의 정의를 도입하여 기업부실화 예측을 실시할 필요가 있다. 방법론적인 관점에서 통계적 기법들은 그 분석을 위해 엄격한 가정들을 만족해야 한다는 한계점이 존재하는데, 이는 모형의 입력변수에 대한 제약조건을 충족하지 못한다면 모형의 성능이 현저히 악화됨을 의미한다. 이것은 모형에 대해 엄격한 가정을 필요로 하지 않으면서도 데이터를 활용하여 종속변수를 설명할 수 있는 방법이 필요함을 시사한다.

선행연구에서의 한계점들을 보완하기 위하여, 본 연구에서는 기업부실화 예측을 위해 한계기업을 예측대상인 종속변수로 사용하고자 한다. 한계기업은 개념적으로 경영이 부실하고 재정적 위기에 빠진 기업이라고 정의할 수 있는데(오영택, 정성필, 2011, 152), 사업활동을 영위하고 있으나 기업의 생존을 위한 적정수준의 이익을 확보하고 있지 못하는 계속기업을 말한다. 이러한 한계기업을 그 예측대상으로 활용함으로써 본 연구는 계속기업 간에 성과의 변화를 지속적으로 관찰하여 관리대상으로 고려해야 할 계속기업이 어떤 기업인지를 판단하고자 한다.

또한, 본 연구에서는 한계기업을 예측하는 방법으로 머신러닝(Machine Learning) 모형 중 하나인 딥러닝(Deep Learning) 기법을 사용하고자 한다. 딥러닝은 인공신경망(ANN, Artificial Neural Network) 이론에 기초를 둔 것으로 인간의 뉴런(Neuron)과 유사한 구조인 입력층(Input Layer)-은닉층(Hidden Layer)-출력층(Output Layer)의 구조를 가지고 모형을 학습 및 예측하는 기법을 말한다(오세경, 최정원, 장재원, 2017, 11). 딥러닝을 비롯한 머신러닝 기

법은 비교적 최근에 회계 및 재무 분야에 도입되기 시작한 방법으로, 이에 속하는 기법들을 활용한 다양한 연구들이 활발하게 이루어지고 있다. 이러한 머신러닝 기법들은 과거부터 널리 이용되어 온 통계기법들에 비해 더욱 우수한 성과를 보이는 것으로 나타났다(차성재, 강정석, 2018, 2). 그러나 딥러닝 기법들을 적용하고 그 예측대상을 한계기업으로 한 연구는 현재 전무한 상황이다. 이에 본 연구에서는 한계기업을 종속변수로 두고 이에 대해 딥러닝 모형들의 적용 가능성을 확인하고자 한다. 그리고 머신러닝 모형 중에서도 그 예측력이 뛰어난 것으로 나타난 앙상블 모형들과 딥러닝 모형들의 예측력을 비교하고자 한다.

본 연구는 다음과 같이 구성되어 있다. 제2장에서는 한계기업의 정의와 선행연구에서 사용된 단일 머신러닝 모형 및 앙상블 모형 기반의 부실기업 예측모형, 딥러닝 기법들의 정의와 관련 선행연구들을 소개한다. 제3장은 데이터 수집 방법, 선정된 재무비율 변수, 데이터 현황 및 기초통계량, 최종적으로 분석에 사용된 모형들로 구성된다. 제4장은 각 모형의 구체적인 초기 설정값과 성능 평가척도를 소개하여 이에 기반한 각 모형의 분석 결과를 설명하고 해석을 기술한다. 제5장은 본 연구의 내용을 요약·정리하고 연구의 시사점과 한계점을 제시한다.

## II. 이론적 배경

### 1. 한계기업의 정의

부실기업은 그 목적에 따라 매우 다양하게 정의될 수 있으므로, 부실기업과 관련된 연구를 수행함에 있어 예측대상을 명확하게 정의하는 과정이 필요하다(조성표, 류인규, 2007, 6). 본 연구에서는 이러한 부실기업 중 한계기업을 예측하고자 하므로, 한계기업을 중심으로 그 정의를 살펴보고자 한다. 오영택, 정성필(2011, 152)은 한계기업을 ‘경영이 부실하고 재정적 위기에 빠진 기업’으로 정의하였다. 그리고 송양호, 정성필(2011, 182)의 연구에서도 이와 유사하게 ‘재무구조가 부실하여 영업활동을 통해 벌어들인 이익으로 이자를 감당하지 못하거나 도산에 이를 정도로 적자상태에 있거나 시장점유율의 저하 등 경쟁력을 상실해 가는 기업’으로 정의하였다. 이기영, 우석진(2015, 76)은 그 요건을 구체화하여 ‘최종 3개년 연속 총차입금이 매출액을 초과하는 기업,’ ‘최종 2개년 연

속 자기자본 전액 잠식 기업, “최종 3개년 연속 이자보상배율 1 미만인 기업”으로 보았다. 한국은행은 2016년 금융안정보고서에서 한계기업을 ‘3년 연속으로 이자보상배율이 1 미만인 기업’으로 정의하였다. 이러한 국내의 한계기업에 대한 정의와는 달리, 일본에서는 ‘수익을 내지 못한 상태이고 차입금 의존도가 높아 은행 대출과 같은 자금지원이 없으면 파산할 위험에 처한 기업’으로 정의하고 있다(Caballero et al, 2008, 1946). 이러한 정의들을 종합하면, 한계기업이란 ‘사업 활동을 수행하고 있지만 부실한 재무구조로 인해 추가적인 지원 없이는 장기적인 관점에서 정상적인 경영을 하기 힘들 것으로 예상되는 기업’을 말한다. 이처럼 다양한 한계기업의 정의 중에서, 본 연구는 국내의 경제 상황에 적합하면서도 국내에서 가장 공신력 있는 기관이라 할 수 있는 한국은행의 한계기업 정의인 ‘3년 연속 이자보상배율이 1 미만인 기업’을 사용하였다.

## 2. 머신러닝을 이용한 부실기업 예측

전술한 바와 같이 부실기업 예측은 오랜 기간 연구가 이루어져 온 주제이다. 이는 기업 부실화와 관련된 비용이 매우 크므로 이해관계자와 국가 경제에 중대한 영향력을 미치는 것에서 기인한다. 머신러닝과 같은 기법들은 기업 부실화를 예측하기 위한 방법론으로 비교적 최근에 제안되기 시작하였다. 이러한 머신러닝은 수많은 분류 문제에 활용되어 왔으며 전통적인 통계 기법들의 성능을 앞서는 것으로 나타났다(윤호중, 2019, 167). 부실기업 예측을 위해 머신러닝이 활용한 연구로, Odom & Sharda(1990, 167)은 인공신경망(Artificial Neural Network) 모형을 활용하여 부도기업을 예측하고 다중판별분석(Multiple Discriminant Analysis)에 비해 그 성능이 우수함을 확인하였다. 이진창(1993, 78)은 다중판별분석, 귀납적 추론, 인공신경망 기법을 적용하여 부도기업을 예측하고 그 성과를 비교한 결과, 인공신경망 기법의 예측력이 가장 뛰어남을 확인하였다. 이재식, 한재홍(1995, 133)은 재무정보만을 활용하여 분석이 이루어진 선행연구를 보완하고자 비재무적 정보를 도입하여 중소기업의 부도를 예측하였고 그 결과 비재무정보를 도입하였을 때 예측력이 향상됨을 보여주었다. Shin et al.(2005, 134)은 인공신경망의 역전파(Back-propagation) 기법에서 적절한 모형의 최적 구조를 찾는 것이 어렵다는 점을 지적하고, 부도기업을 예측하는데 서포트 벡터 머신(Support Vector Machine)이 인공신경망에 비해 더 우수한 성과를 보이

는 것을 검증하였다. Kim & Sohn(2010, 844)은 서포트 벡터 머신으로 중소기업의 부도 가능성을 예측하여 인공신경망과 로지스틱 회귀모형보다 우수한 예측 성과를 가지는 것을 확인하였다. Le & ViViani(2012, 24)는 은행의 부도예측을 위하여 전통적인 통계기법과 인공신경망, 서포트 벡터 머신을 활용 및 예측 성능을 비교한 결과 인공신경망과 서포트 벡터 머신의 예측 정확성이 더 우수함을 확인하였다. 오우석, 김진화(2017, 31)는 전통적인 통계기법들과 인공신경망, 의사결정나무(Decision Tree) 모형을 적용하여 부도기업을 예측한 결과, 의사결정나무 모형이 가장 성능이 우수하다는 결론을 내렸다. 이찬호 등(2020, 664)은 부실 징후 기업 중 한계기업의 예측하고자 다양한 머신러닝 기법을 활용하여 예측을 실시한 결과, K-최근접이웃법의 성능이 가장 우수함을 확인하였다.

이처럼 머신러닝은 1990년대부터 많은 연구에서 기업부실화 예측에 적용되어 그 유용성을 보여왔다. 단일 머신러닝 기법에 기반한 선행연구들은 주로 전통적인 기법이나 다른 머신러닝 기법과의 성능을 비교함으로써 머신러닝이 우수함을 보이고자 하였다. 본 연구 또한 이러한 선행연구의 기초에 따라 딥러닝 모형들과 다양한 머신러닝 모형들을 비교함으로써 한계기업 예측에 대한 딥러닝의 적용 가능성을 제시하고자 한다.

## 3. 머신러닝 앙상블 모형 부실기업 예측

머신러닝을 활용한 부실기업을 예측하는 연구들이 제안된 이후, 모형의 성능 개선을 위하여 머신러닝 앙상블(Ensemble) 모형을 적용한 연구가 활발하게 수행되기 시작하였다. 앙상블 모형은 개별 분류기(Classifier)를 사용한 경우에 비해 더 좋은 예측 성과를 얻고자 다수의 분류기를 결합하여 사용하는 것을 의미하며, 일반적으로 개별 분류기의 일반화 성능을 향상시키는데 있어 유용한 것으로 알려져 있다(민성환, 2016, 139). 이러한 머신러닝 앙상블 모형을 활용하여 부실기업을 예측한 연구로, 김승혁, 김종우(2007, 23)는 기업부도를 예측하기 위하여 인공신경망, 의사결정나무 모형, 배깅(Bagging) 모형을 적용한 결과 배깅 앙상블 모형의 예측 성과가 가장 우수함을 보여주었다. Tsai & Wu(2008, 2648)는 인공신경망 모형을 활용하여 앙상블 모형을 구성하고 단일 인공신경망 모형과 그 예측 성과를 비교하였는데, 단일 인공신경망 모형보다 인공신경망 앙상블 모형의 예측력이 더 우수함을 밝혔다. 김명중(2009, 10)은 기업부도 예측에서 발생하기 쉬운 데이터 불균형 문제를 해결하기 위하여 기하평균에 기반한 부스팅 앙상블 모형인

GM-Boosting 알고리즘을 제안하였으며, 분석 결과 데이터 불균형과 관계없이 일정한 예측 성과를 보이는 것을 확인하였다. 배재권(2010, 97)은 효과적인 부도기업 예측을 위하여 전통적인 통계기법과 머신러닝 기법을 통합한 5가지 모형을 제안하였는데, 그중에서도 Voting 알고리즘과 인공신경망을 통합한 모형이 예측 정확성의 관점에서 가장 우수한 성과를 보여준다고 말하였다. 최하나, 임동훈(2013, 1123)은 서포트 벡터 머신에 기반한 앙상블 모형이 기업부도 예측에 있어 우수한 성능을 보이는지를 확인하고자 하였다. 이를 위해 기업의 실제 재무비율 자료 및 모의실험 자료를 활용하여 검증한 결과 단일 서포트 벡터 머신 모형에 비해 앙상블 모형이 좋은 성능을 가짐을 제시하였다. 민성환(2016, 18)은 K-최근접 이웃법(K-Nearest Neighborhood)으로 앙상블 모형을 구성하여 기업부도를 예측하였는데, K-최근접 이웃법의 입력변수들을 변화시키면서 최적의 값을 결정하는 새로운 방법을 제안 및 적용한 결과 그 예측 성능이 단일 K-최근접 이웃법에 비해 우수함을 보여주었다. Barboza et al(2017, 415)는 기업의 부도예측을 위해 다중판별분석, 로지스틱 회귀 모형, 서포트 벡터 머신, 인공신경망, 랜덤포레스트 등 다양한 모형들을 재무비율 변수에 기반하여 예측 성능을 비교하였고, 의사결정나무를 배경 방식으로 결합한 랜덤포레스트가 가장 분류정확도가 뛰어남을 제시하였다. 엄하늘, 김재성, 최상욱(2020, 123)은 기업 부도를 예측하기 위하여 랜덤포레스트(Random Forest), 인공신경망, 합성곱신경망(CNN, Convolutional Neural Network)을 결합한 스택킹 앙상블 모형을 제안하였고 이를 바탕으로 개별 머신러닝 기법이 가질 수 있는 예측 편향을 완화할 수 있다고 말하였다.

이처럼 많은 선행연구에서 제시된 바와 같이 머신러닝 앙상블 모형은 단일 머신러닝 기법에 비해 그 예측 성능이 우수한 것으로 나타났다. 앙상블 모형을 구성하는 방법은 다양하며 그 방법에 따라 성능의 차이가 존재한다. 하지만 선행연구에서는 이러한 머신러닝 앙상블 모형과 딥러닝 기법의 성능 차이를 비교하는 연구는 거의 이루어지지 않았다. 따라서 본 연구에서는 머신러닝 앙상블 모형으로 한계기업 예측을 실시하고 이를 딥러닝의 분석 결과와 비교하여, 딥러닝 기법의 한계기업 예측에 대한 그 적용의 필요성을 제시하고자 한다.

#### 4. 딥러닝 기반 부실기업 예측

딥러닝(Deep Learning)이란 머신러닝 모형 중 하나로 다수의 비선형 변환기법을 조합하여 대량의 데이터 혹은 복잡한 데

이터에서 주요 특성들을 추출하는 알고리즘들을 총칭한다(Bengio et al, 2013, 1798). 앞서 언급한 바와 같이 딥러닝은 인공신경망 이론에 기반을 둔 것으로(오세경, 최정원, 장재원, 2017, 11), 인간의 뉴런과 비슷한 구조를 가지고 컴퓨터 등과 같은 기계를 학습시켜 문제를 해결한다. 가장 대표적인 딥러닝 모형인 심층신경망(Deep Neural Network)은 입력층(Input Layer)과 출력층(Output Layer) 사이에 1개 이상의 은닉층(Hidden Layer)이 존재하는 인공신경망 모형을 말한다. 이러한 심층신경망에는 이전 단계의 학습 데이터를 다음 단계의 학습에서 활용하여 예측을 실시하는 순환신경망(Recurrent Neural Network)이 있다(Mikolov, 2010, 1046). 최근 들어, 순환신경망에서 발생할 수 있는 기울기 소실(Vanishing Gradient) 문제를 줄이고 학습속도를 높여주는 LSTM(Long Short Term Memory)과 GRU(Gated Recurrent Units)를 적용한 연구가 증가하고 있다. 또 다른 대표적 기법으로 입력층과 출력층 사이에 합성곱층(Convolutional Layer), 풀링층(Pooling Layer) 등으로 구성된 합성곱신경망(Convolutional Neural Network)이 있으며(LeCun & Bengio, 1995, 6) 이외에도 많은 딥러닝 모형들이 존재한다.

부실기업 예측을 위해 딥러닝을 적용한 연구로, Yeh et al(2015, 162)은 심층신뢰망(Deep Belief Network)을 이용하여 기업이 도산할 확률을 예측하였으며, 심층신뢰망이 다른 머신러닝 모형에 비해 탁월한 성과를 보이는 것을 제시하였다. 권혁진 등(2017, 148)은 순환신경망 모형을 적용하여 기업부도 예측을 실시하였고, 그 결과 타 모형에 비해 순환신경망 모형의 예측 성능이 우수함을 확인하였다. 차성재, 강정석(2018, 24)은 딥러닝 기법 중 순환신경망과 그 외 전통적인 통계기법 및 머신러닝 모형들의 기업부도 예측에 관한 성과를 비교하였고, 그 결과 LSTM이 적용된 순환신경망 모형이 우수한 성능을 보임을 제시하였다. Mai et al(2019, 743)는 기업들의 부도예측을 위하여 여러 재무변수 및 경영공시 정보 데이터를 활용해 딥러닝 및 머신러닝 모형들로 분석한 결과, 딥러닝 모형들의 예측 성능이 더욱 우수하다고 시사하였다. Alexandropoulos et al(2019, 435)는 여러 재무변수를 통해 기업의 부도 가능성을 예측하기 위하여 다층 퍼셉트론, 로지스틱 회귀 모형 등의 모형과 딥러닝 모형을 활용하여 예측을 실시하였고, 다른 기법에 비해 딥러닝 모형이 탁월한 예측에 있어 탁월한 성과를 보임을 증명하였다. Arratia & Sepúlveda(2019, 68)는 기업의 부도예측에 있어 합성곱신경망 모형이 유용할 수 있음을 시사하였으며, 기업의 재무변수들을 이미지화하여 특징을 추출할 경우 그

예측력이 높아질 수 있음을 제시하였다. Hosaka(2019, 298)는 기업부도를 예측하고자 합성곱신경망을 활용하기 위하여 분석대상 기업들의 데이터를 이미지화한 후 분석을 실시하였는데, 전통적인 통계기법들에 비해서 합성곱신경망이 더 우수한 부도예측 성능을 보인다고 말하였다. Vochozka et al(2020, 14)는 심층신경망 모형(Deep Neural Network)에 LSTM을 적용하여 기업의 부도 여부를 예측하고자 하였으며, 활성화수, 노드의 수 등을 변화시키며 최적의 예측 성능을 보여주는 신경망 구성방법을 찾아내고자 시도하였다.

그러나 다양한 분야에서 검증된 유용성에도 불구하고 딥러닝을 이용하여 부실기업을 예측한 연구는 현재까지 적으며, 국내 상황에 맞춘 종속변수라 할 수 있는 한계기업을 예측하는 데는 딥러닝 기법을 적용한 연구가 없는 상황이다. 그러므로 본 연구에서는 한계기업의 예측에 있어 딥러닝 기법들을 적용함으로써 그 예측성능을 다른 머신러닝 앙상블 모형과 비교 및 우수성 검증을 실시한다.

### III. 연구 설계

#### 1. 수집 데이터 및 전처리 설명

본 연구에서 모형 간의 예측 성능을 비교하기 위해 사용된 데이터에 대한 설명과 전처리 과정은 <표 1>에 제시되어 있다. 분석을 위해 KISVALUE에서 제공하는 기업 재무데이터를 사용하였다. 분석대상은 KOSPI, KOSDAQ, KONEX에 주식이 상장된 상장기업 및 외부감사 대상기업 33,916개의 기업이다. 이들 기업의 2017~2019년 공식정보를 분석하며, 비금융업이면서 결산월이 12월인 기업만을 분석에 활용하였다. 이와 같이 분석대상 기업을 한정한 이유는 금융업이 영업활동

및 재무제표 제정의 특성이 타 업종과 상이함을 고려하고 결산월의 차이에 따른 영향이 데이터에 왜곡을 일으키는 것을 방지하기 위함이다(강순심, 김정재, 2014, 14). 또한, 데이터의 객관성을 확보하기 위해 설립일이 2016년 이후이면서 분석대상 기간에 '적정'이외의 감사의견을 받은 기업은 분석대상에서 제외하였다. 이때 분기 및 반기 재무제표는 회계감사를 거치지 않아 경영진이 재무제표 항목에 부당한 영향력을 행사할 유인이 있는 등의 이유로 신뢰성이 상대적으로 낮기에(이화득, 육근구, 2004, 4) 연차 재무제표 정보만을 분석에 활용하였다. 그 결과, 최종적으로 16,813개의 기업이 분석대상으로 선정되었다. 해당 기업의 데이터에 대한 결측치는 결측치를 제거하는 방법을 사용하였을 경우 생존한 데이터에 대해 편향 문제가 발생할 수 있으므로 중앙값(Median) 대체를 통하여 처리하였다. 단, 한계기업의 판단 척도로 사용되는 영업이익이 자보상비율에서 결측치가 존재하는 경우, 해당 기업정보를 제거함으로써 실제 한계기업만을 분석에 사용되도록 하였다.

또한, 분석과정에 영향을 미칠 수 있는 이상치(Outlier)를 처리하는 방법으로 윈저라이징(Winsorizing)을 적용하여 이상치들을 변수별로 분포상 누적확률 0.01, 0.99에 해당하는 값들로 변환하였다. 이러한 데이터 전처리 과정을 바탕으로 얻은 분석대상 표본에서 2017~2019년의 3개년의 영업이익이 자보상비율이 1 미만인 기업을 한계기업으로, 그 이외의 기업은 정상기업으로 분류하였다. 그 결과 최종적인 정상기업과 한계기업의 수는 각각 13,818개, 2,995개로 집계되었다.

#### 2. 변수선정 및 평가척도

본 연구에서는 종속변수로 설정한 한계기업을 예측하기 위한 독립변수로 각 기업의 재무비율들을 활용하였으며,

<표 1> 수집 데이터 및 전처리 과정

| 구 분        | 설 명  |
|------------|--|
| 분석대상       | <ul style="list-style-type: none"> <li>• 2017~2019년 KOSPI, KOSDAQ, KONEX 상장기업 및 외부감사 대상기업 16,813개 기업의 재무정보</li> <li>• 16년 이후 설립 및 적정 감사의견 외 기업을 제외한 비금융업 업종의 12월 결산법인</li> </ul>                                   |
| 데이터 전처리    | <ul style="list-style-type: none"> <li>• 결측치 처리 : 기업정보 결측치에 대해 중앙값(Median) 대체 적용</li> <li>※ 영업이익이자보상비율에서 결측치가 존재하는 경우에는 해당 기업 데이터 제거</li> <li>• 이상치 처리 : 윈저라이징(Winsorizing)을 통해 0.01, 0.99에 해당하는 값으로 변환</li> </ul> |
| 표본         | <ul style="list-style-type: none"> <li>• 한계기업 : 2017~2019년 영업이익이자보상비율이 1 미만인 기업</li> <li>• 정상기업 : 한계기업 이외의 기업</li> <li>※ 2019년을 기준으로 3개년도의 영업이익이자보상비율이 1 미만인지 여부 판단</li> </ul>                                     |
| 최종 분석 대상기업 | <ul style="list-style-type: none"> <li>• 정상기업 : 13,818개</li> <li>• 한계기업 : 2,995개</li> </ul>  |

구체적인 재무비율들과 그 분류는 다음의 <표 2>에 제시되어 있다.

재무비율은 기업의 재무제표에서 얻을 수 있는 회계정보를 바탕으로 산출되는 변수로, 부도기업 등 부실기업 예측을 위해 많은 연구에서 사용된 바 있다(이인로, 김동철, 2015, 630). 또한, 외부감사를 받는 기업의 정보는 그 신뢰성이 검증되었을 뿐만 아니라 이러한 재무정보를 바탕으로 산출된 재무비율로 기업부실을 예측하는 것은 모형 구축의 용이성과 비용 측면에서 우수한 성과를 보일 수 있으며, 재무제표의 정보가 가지는 예측력과 관련하여 이론적 및 실무적으로 중요한 의미를 가진다(박종원, 안성만, 2014, 639). 또한, 재무비율은 상장기업과 비상장기업의 가치 평가에 공통적으로 사용할 수 있는 평가지표이자 투자자들의 재무적 의사결정에 있어 중요한 수단이라고 할 수 있다(김선배 등, 2016, 5). 그러므로 본 연구 또한 딥러닝 및 머신러닝 모형을 통한 한계기업 예측에 있어 이러한 재무비율을 이용하고자 한다.

<표 2>에서 제시한 바와 같이 재무비율들은 그 특성에 따라 일반적으로 성장성 지표, 수익성 지표, 활동성 지표, 안정성

지표로 분류할 수 있다. 성장성 지표는 총자산, 매출액 등 재무상태나 경영성과 등이 전기 대비 당기에 얼마나 증감하였는지를 나타내는 지표이다. 수익성 지표는 기업의 투자활동 및 영업활동을 통한 기업의 수익성을 평가하는 것으로 전기 대비 당기에 이익 또는 손실이 얼마나 발생하였는지를 보여주는 지표이다. 활동성 지표는 기업이 현재 보유 중인 자산을 당기에 얼마나 효율적으로 운용하였는지를 측정하는 지표이다. 안정성 지표는 기업의 단기 및 장기채무상환능력과 현금창출능력을 나타내는 지표이다.

이러한 후보 재무비율을 대상으로 다음과 같은 절차에 따라 모형들의 학습에 사용할 최종 재무비율을 결정하였으며 그 결과는 <표 3>에 제시되어 있다. 먼저, 재무비율별로 독립표본 t 검정(Independent t-test)을 진행하여 p-value가 0.05보다 큰 연도별 재무비율을 제외하였다. 이것은 변수의 데이터 분포가 정상기업과 한계기업 간에 유의한 차이가 없어 설명력을 가지지 못하는 경우, 이러한 변수를 제거하고 한계기업 여부에 대해 설명력을 가지는 유의변수만을 분석에 사용하기 위한 것이다. 그리고 연도별 재무비율들을 대상으

<표 2> 선정된 후보 재무비율

| 구분 | 분류  | 명칭        | 산식   |
|----|-----|-----------|--|
| 1  | 성장성 | 총자산증가율    | $(\text{기말총자산} - \text{기초총자산}) / \text{기초총자산} \times 100$    |
| 2  |     | 유동자산증가율   | $(\text{기말유동자산} - \text{기초유동자산}) / \text{기초유동자산} \times 100$ |
| 3  |     | 매출액증가율    | $(\text{당기매출액} - \text{전기매출액}) / \text{전기매출액} \times 100$    |
| 4  |     | 순이익증가율    | $(\text{당기순이익} - \text{전기순이익}) / \text{전기순이익} \times 100$    |
| 5  |     | 영업이익증가율   | $(\text{당기영업이익} - \text{전기영업이익}) / \text{전기영업이익} \times 100$ |
| 6  | 수익성 | 매출액순이익률   | $\text{순이익} / \text{매출액} \times 100$                         |
| 7  |     | 매출총이익률    | $\text{매출총이익} / \text{매출액} \times 100$                       |
| 8  |     | 자기자본순이익률  | $\text{순이익} / \text{자기자본} \times 100$                        |
| 9  | 활동성 | 매출채권회전율   | $\text{매출액} / \text{매출채권}$                                   |
| 10 |     | 재고자산회전율   | $\text{매출원가} / \text{재고자산}$                                  |
| 11 |     | 총자본회전율    | $\text{매출액} / \text{총자본}$                                    |
| 12 |     | 유형자산회전율   | $\text{매출액} / \text{총자산}$                                    |
| 13 |     | 매출액대매출원가  | $\text{매출원가} / \text{매출액} \times 100$                        |
| 14 |     | 매출액대판매관리비 | $\text{판매관리비} / \text{매출액} \times 100$                       |
| 15 | 안정성 | 부채비율      | $\text{부채} / \text{자기자본} \times 100$                         |
| 16 |     | 유동비율      | $\text{유동자산} / \text{유동부채} \times 100$                       |
| 17 |     | 자기자본비율    | $\text{자기자본} / \text{총자산} \times 100$                        |
| 18 |     | 당좌비율      | $\text{당좌자산} / \text{유동부채} \times 100$                       |
| 19 |     | 고정비율      | $\text{고정자산} / \text{총자본} \times 100$                        |
| 20 |     | 순운전자본비율   | $\text{순운전자본} / \text{총자본} \times 100$                       |
| 21 |     | 차입금의존도    | $(\text{장기 및 단기차입금} + \text{사채}) / \text{총자본} \times 100$    |
| 22 |     | 현금비율      | $\text{현금예금} / \text{유동부채} \times 100$                       |

〈표 3〉 최종 선정된 연도별 재무비율

| 구분 | 2017년      | 2018년      | 2019년     |
|----|------------|------------|-----------|
| 1  | 총자산증가율     | 총자산증가율     | 총자산증가율    |
| 2  | 유동자산증가율*   | 유동자산증가율    | 유동자산증가율*  |
| 3  | 매출액증가율     | 매출액증가율*    | 매출액증가율*   |
| 4  | 순이익증가율*    | 순이익증가율*    | 순이익증가율*   |
| 5  | 영업이익증가율*   | 영업이익증가율*   | 영업이익증가율   |
| 6  | 매출액순이익률    | 매출액순이익률*   | 매출액순이익률   |
| 7  | 매출총이익률*    | 매출총이익률     | 매출총이익률    |
| 8  | 자기자본순이익률*  | 자기자본순이익률*  | 자기자본순이익률* |
| 9  | 매출채권회전율    | 매출채권회전율    | 매출채권회전율   |
| 10 | 재고자산회전율    | 재고자산회전율    | 재고자산회전율   |
| 11 | 총자본회전율*    | 총자본회전율     | 총자본회전율*   |
| 12 | 유형자산회전율    | 유형자산회전율    | 유형자산회전율*  |
| 13 | 매출액대매출원가   | 매출액대매출원가*  | 매출액대매출원가  |
| 14 | 매출액대판매관리비* | 매출액대판매관리비* | 매출액대판매관리비 |
| 15 | 부채비율       | 부채비율*      | 부채비율      |
| 16 | 유동비율       | 유동비율*      | 유동비율*     |
| 17 | 자기자본비율     | 자기자본비율*    | 자기자본비율*   |
| 18 | 당좌비율*      | 당좌비율*      | 당좌비율      |
| 19 | 고정비율*      | 고정비율*      | 고정비율*     |
| 20 | 순운전자본비율    | 순운전자본비율    | 순운전자본비율*  |
| 21 | 차입금의존도*    | 차입금의존도     | 차입금의존도*   |
| 22 | 현금비율*      | 현금비율       | 현금비율      |

\* 연도별 최종 선정된 변수

로 로지스틱 회귀분석을 실시하고 후진선택법(Backward Selection)을 사용하여 종속변수인 한계기업 여부에 대해 설명력이 우수한 재무변수군을 추출하였다. 후진선택법이란 잠정적인 독립변수로 선정된 전체 변수군을 대상으로 독립변수군에서 제외하여도 종속변수에 대한 설명력에 영향을 미치지 않는 변수들을 순차적으로 제거하는 방법을 의미한다. 선정 결과, 2017년 11개, 2018년 12개, 2019년 11개의 재무비율이 2019년 기준 한계기업 여부에 대해 설명력을 가지는 변수인 것으로 나타났다.

선정된 연도별 재무비율을 바탕으로 모형을 학습하여 예측을 실시할 경우, 예측 결과에 대해 평가를 위한 척도가 필요하다. 본 연구에서 예측하고자 하는 것은 한계기업 여부이고 이는 이진 분류 문제(Binary Classification Problem)에 해당한다. 이진 분류 문제는 예측 결과의 수가 2가지이므로 다음의 〈표 4〉에 제시된 혼돈행렬(Confusion Matrix)로 가능한 모든 경우의 수를 표시할 수 있다.

이러한 혼돈행렬을 바탕으로 모형들의 성과를 측정하는 여

〈표 4〉 혼돈행렬(Confusion Matrix)

| 실제 \ 예측  | Positive                        | Negative                        |
|----------|---------------------------------|---------------------------------|
| Positive | True Positive<br>( <i>TP</i> )  | False Negative<br>( <i>FN</i> ) |
| Negative | False Positive<br>( <i>FP</i> ) | True Negative<br>( <i>TN</i> )  |

러 척도를 산출할 수 있는데, 대표적으로 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1-점수(F1-Score)가 있다. 정확도는 예측값이 실제값을 얼마나 정확하게 예측하였는가를 나타내는 척도로 전체 데이터에 대한 정확한 분류의 비율이다. 정밀도는 모델의 예측값 중 정확하게 예측된 데이터의 비율을 나타낸다. 재현율은 전체 실제값 중에서 모델이 예측한 실제값의 비율을 나타내는 척도이다. F1-점수는 재현율과 정밀도의 조화평균이다. 본 연구에서 이러한 평가척도들을 사용하여 머신러닝 및 딥러닝 기법들의 예측 성능을 측정한다. 본 연구에서 활용하는 척도들의 산식을 표현하면 다음의

〈표 5〉 평가척도 및 산식

| 평가척도                | 산식  |
|---------------------|---|
| 정확도<br>(Accuracy)   | $\frac{TP + TN}{TP + TN + FP + FN}$                                 |
| 정밀도<br>(Precision)  | $\frac{TP}{TP + FP}$  |
| 재현율<br>(Recall)     | $\frac{TP}{TP + FN}$  |
| F1-점수<br>(F1-Score) | $\frac{2(\text{재현율} \times \text{정밀도})}{(\text{재현율} + \text{정밀도})}$ |

〈표 5〉와 같다.

일반적으로 정확도를 기준으로 예측 성능을 평가하지만 상대적으로 소수인 집단의 분류에서는 예측 성과를 무시한다는 단점이 있어서 다양한 척도를 활용하여 그 성능을 평가할 필요가 있다(이찬호 등, 2020, 655).

### 3. 예측을 위한 모형

#### 1) 머신러닝 앙상블 모형

본 연구에서 딥러닝 모형과의 예측성능 비교를 위해 선정한 모형은 머신러닝 앙상블(Machine Learning Ensemble) 모형이다. 전술한 바와 같이 앙상블 모형은 다수의 분류기를 결합하여 예측을 실시하는 모형으로 단일 분류기만을 사용하는 모형에 비해 더욱 우수한 성능을 나타내는 것으로 알려져 있다(Dietterich, 1997, 97). 분류기를 결합하는 방법은 다양한 방법이 존재하며, 대표적으로 배깅(Bagging)과 부스팅(Boosting) 등이 있다. 본 연구에서는 이러한 분류기 결합 방법 중 배깅을 사용하였다. 배깅은 모형의 학습을 위한 데이터를 복원추출하여 무작위로 부분집합을 발생시키는 것으로, 이러한 과정을 거쳐 생성한 서로 다른 학습 데이터들을 통해 분류기들을 학습 및 성능 평가를 한 후 분류기들의 결과를 바탕으로 최종적인 예측 결과를 산출한다(민성환, 2014, 126).

본 연구에서는 앙상블 모형을 구성하는 분류기로 의사결정나무(Decision Tree), 서포트 벡터 머신(Support Vector Machine), K-최근접 이웃법(K-Nearest Neighbor)을 사용하였다. 제2장에서 소개된 선행연구의 결과에서 볼 수 있듯이 이들 모형은 앙상블 모형으로 결합되었을 때 우수한 예측 성과를 보인다. 이때, 의사결정나무 방법을 배깅 방식을 통해 결합하였을 경우 이는 랜덤포레스트(Random Forest)로 불린다. 따라서 최종적으로 랜덤포레스트, 서포트 벡터 머신 앙

상블, K-최근접이웃법 앙상블을 딥러닝 모형의 비교를 위해 사용하였다.

#### 2) 딥러닝 모형

본 연구에서 예측 성능 비교를 위해 딥러닝 모형은 순환신경망(RNN, Recurrent Neural Network) 모형과 합성곱신경망(CNN, Convolutional Neural Network) 모형을 선정하였다. 앞서 언급한 바와 같이 두 모형은 다양한 분야에서 활용되고 있는 딥러닝 기법들이다. 또한, 부실기업을 예측하기 위한 연구들에서도 그 유용성을 시사하는 결과를 보여주었다. 본 연구에서 한계기업 예측을 위해 활용한 딥러닝 모형들을 간략히 소개하면 다음과 같다.

##### (1) 순환신경망 모형(RNN)

순환신경망 모형은 인공신경망 기법의 하나로, 신경망 내 모든 노드가 자기 순환적으로 연결된 구조를 통해 순차적인 데이터를 처리하여 특정 대상을 예측하는 딥러닝 알고리즘이다(방성혁 등, 2018, 361). 인공신경망이 산출된 결과값과 실제 값과의 차이를 최소화하는 최적의 가중치를 찾기 위해 입력데이터가 모든 노드와 1번씩 계산되는 것과는 달리, 순환신경망은 이전 시점의 출력값이 현재 시점의 가중치 계산에 반영되는 구조를 가져 과거의 정보가 현재 시점의 출력값에 영향을 미친다는 점에서 그 차이가 있다(권혁진 등, 2017, 141). 특히, 순환신경망 모형의 경우에는 시간의 흐름에 따른 데이터의 변동 양상을 연속적으로 계산하여 예측을 실시하기 때문에(김종화 등, 2019, 1774), 시계열 분석(Time-series Analysis)이 필요한 연구에서 자주 활용되고 있다.

그러나 순환신경망 모형은 시간이 지남에 따라 기울기 값이 0으로 수렴 또는 무한정으로 발산하는 현상인 기울기 소실(Vanishing Gradient)이 발생하여 이전 시점에 입력된 데이터들이 현재 시점의 출력값 계산에 영향을 미치지 못한다는 문제점을 가지고 있다. 이를 보완하는 방법으로 LSTM(Long Short Term Memory)과 GRU(Gated Recurrent Unit)가 제안되었다(이선민 등, 2019, 80). LSTM은 어떠한 데이터를 버릴지 결정하는 망각게이트, 어떠한 데이터를 갱신할지를 결정하는 입력게이트, 어떠한 값을 출력할지를 결정하는 출력게이트로 구성되어 있으며 이들 3가지 게이트를 통해 최종 결과값을 산출한다. GRU는 이전 결과값을 얼마나 기억할지를 결정하는 갱신게이트, 이전 결과값과 새로운 입력 데이터를 결합하는 리셋게이트로 구성되어 있다. 많은 선행연구에서 순환



신경망에 LSTM 혹은 GRU를 결합할 경우 예측 성능이 향상됨을 시사하였다. 본 연구에서도 이러한 순환신경망의 단점과 연구 동향을 고려하여 RNN-LSTM과 RNN-GRU를 한계기업 예측에 적용하였다.

## (2) 합성곱신경망 모형(CNN)

합성곱신경망 모형은 입력데이터와 데이터의 특징을 추출하는 필터(Filter)의 합성곱(Convolution)을 이용하는 딥러닝 모형으로, 입력층과 출력층 사이에 1개 이상의 합성곱층(Convolution Layer)과 풀링층(Pooling)층을 가지는 특징이 있다(엄하늘 등, 2020, 110). 합성곱층은 입력된 데이터의 합성곱 연산을 실시하고 필터를 통해 데이터의 특징이 추출하며, 풀링층은 합성곱층의 결과값을 단순화하고 크기를 줄이는 역할을 수행한다(김승수, 김중우, 2018, 224). 합성곱신경망 모형은 이미지 처리에 우수한 성과를 가지는 것으로 잘 알려져 있으나, 그 외 다양한 분류 문제에서도 탁월한 성능을 보이는 것으로 나타났으며 부실기업 예측에도 점차 적용되는 추세이다. 그러므로 본 연구에서는 한계기업을 예측하기 위한 딥러닝 모형으로 합성곱신경망 모형 또한 활용하여 그 성능을 비교하고자 하였다.

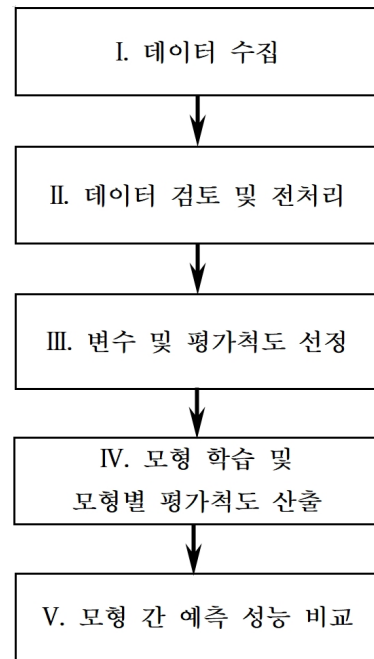
앞서 기술한 본 연구의 설계와 수행 절차는 <그림 1>에 요약되어 있다. 이러한 절차를 바탕으로 한계기업 예측에 있어 딥러닝 모형들과 머신러닝 앙상블 모형들을 학습하고 그 성능을 4가지의 척도에 따라 평가하였다. 분석 결과는 4장에 자세히 소개되어 있다.

## IV. 분석 결과

### 1. 모형 파라미터 설정

선정한 모형들의 학습과 예측력 검증을 위하여 전체 분석 데이터를 70 대 30의 비율로 각각 학습용 데이터와 테스트용 데이터로 구분하였다. 그리고 모형의 학습 및 예측력 검증에 앞서 모든 데이터를 정규화(Normalization)하여 변수별로 단위가 상이한 문제를 제거함과 동시에 동일한 범위 내에서 값을 가지도록 하였다.

이러한 데이터 설정과 더불어 예측 성능을 측정하는 머신러닝 앙상블과 딥러닝 모형의 하이퍼 파라미터(Hyper Parameter)는 다음과 같다. 먼저 머신러닝 앙상블 모형들에 대한 하이퍼



<그림 1> 연구 설계와 수행절차

파라미터는, 랜덤포레스트는 의사결정나무의 수를 의미하는  $n\_estimator$ 를 50으로 설정하고 의사결정나무의 깊이를 나타내는  $max\_depth$ 는 5, 노드의 분할을 위한 최소한의 데이터 수는 10으로 설정하였다. 서포트 벡터 머신 앙상블 모형은  $n\_estimator$ 를 50, 벌칙 모수  $C$ 는 2, 커널 함수는 선형 커널(Linear Kernel)을 사용하였다. K-최근접 이웃법 앙상블 모형은  $n\_estimator$ 를 50, 거리 추정 방식은 유클리디언 거리(Euclidean Distance), 데이터의 분류를 위해 참고할 근접 데이터 수를 의미하는  $k$ 는 30으로 설정하였다.

다음으로 딥러닝 모형에 대한 하이퍼 파라미터이다. RNN-LSTM과 RNN-GRU는 총 4개의 은닉층에서 각 셀을 128개로 설정하였으며, epoch는 200, 활성화 함수(Activation Function)는 모두 렐루(ReLU) 함수를 설정하였다. 그리고 모형의 과적합(Over-fitting) 문제를 피하고자 학습 이후에도 성능 개선이 이루어지지 않으면 학습을 조기 중단하도록 하였다. 합성곱신경망 모형은 4개의 은닉층 수에 Filter 크기를 128로, 특징 추출을 위한 맥스풀링(MaxPooling) 및 학습속도 개선을 위해 0.25의 드롭아웃(Dropout)을 삽입하였으며 활성화 함수로는 렐루(ReLU)를 사용하였다. 딥러닝 모형들의 손실함수(Loss Function)와 옵티마이저(Optimizer)는 모두 Binary Crossentropy와 Adam으로 설정하였다. 모형들의 주요 파라미터 및 설정을 구현하기 위하여 Python 3.8.5 프로그램을 사용하였다. 머신러닝 앙상블 모형은 Python의 Scikit-Learn 0.24.1

라이브러리를 통해 3가지 머신러닝 모형들을 각각 배경 방식으로 구성하였고, 딥러닝 모형들은 Tensorflow 2.4.0 및 Keras 2.4.3 라이브러리를 활용하였다.

## 2. 모형별 분석 결과

이러한 모형들의 하이퍼 파라미터 설정을 토대로 정확도, 정밀도, 재현율, F1-점수의 관점에서 측정한 예측 성능은 <표 6>에 제시되어 있다.

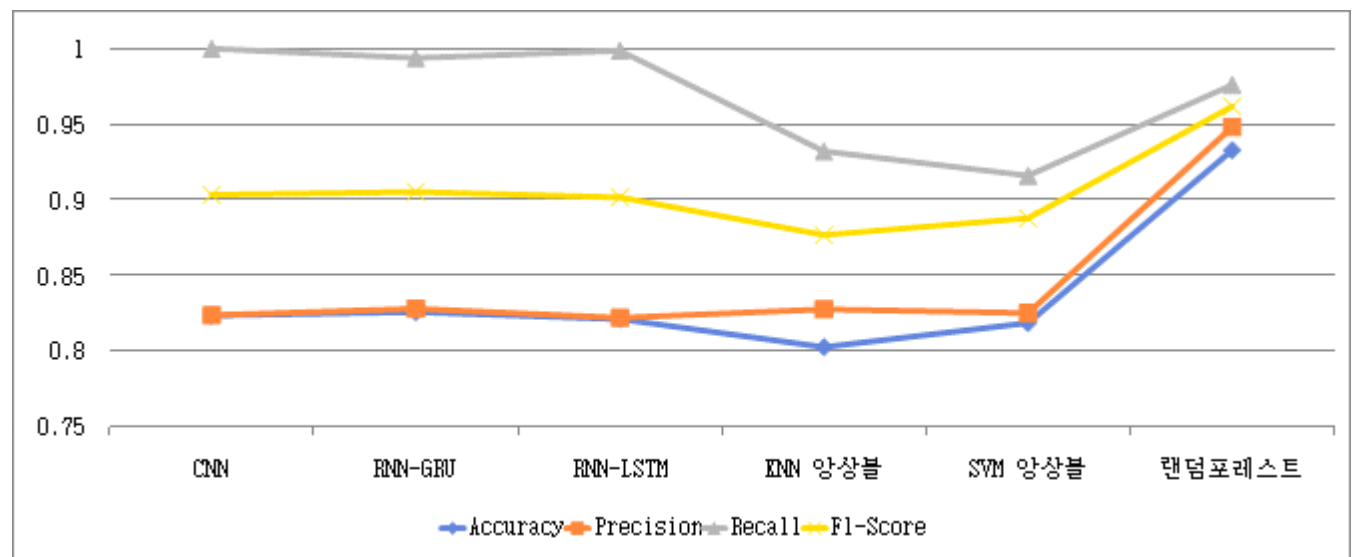
결과값을 살펴보면 랜덤포레스트 모형이 재현율을 제외한 모든 평가척도에서 가장 우수한 예측 성능을 보이는 것으로 나타났다. 특히 정확도와 정밀도 측면에서 타 모형의 수치가 80% 수준으로 산출되는 반면, 랜덤포레스트는 모두 90%를 상회하는 것으로 나타났다. 그러나 재현율에서는 딥러닝 모형인 RNN-LSTM, RNN-GRU, CNN의 성과가 머신러닝 앙상블 모형과 비교해 우수한 결과를 보이는 것으로 나타났다. F1-점수의 관점에서는 랜덤포레스트를 제외한 다른 머신러

닝 앙상블 모형에 비해 딥러닝 모형들이 우수한 예측 성능을 보이는 것으로 나타났다. 이러한 예측 결과를 그래프로 나타내면 <그림 2>와 같다. 정확도, 정밀도, F1-점수는 랜덤포레스트가 그 성능이 가장 우수한 것으로 나타났지만, 재현율의 관점에서는 딥러닝 모형들의 성능이 머신러닝 앙상블 모형들에 비해 우수한 것으로 나타났다.

이러한 평가척도 중 한계기업 예측에서는 재현율이 중요한 지표로 다루어질 수 있다. 재현율은 다른 평가척도와 마찬가지로 오분류 문제인 제1종 오류와 제2종 오류(Type II error)와 관련이 있다. 이때, 제2종 오류는 부실기업 예측의 관점에서 ‘실제 부실기업임에도 불구하고 정상기업으로 예측하는 오류’로 해석될 수 있는데(Lee et al, 2002, 251), 이것은 학습 모형이 위험에 처해 있는 기업을 정확히 판단할 수 없다는 것을 의미하므로 부실기업 예측에 있어서 더욱 중요하다(Reibiro, Lopes, & Silva, 2010, 5). 만약 부실기업을 정상기업으로 잘못 예측한다면 부실기업에 대한 대출 승인이나 잘못된 회계감

<표 6> 모형별 정확도, 정밀도, 재현율, F1-점수

| 모형            | 평가척도 | 정확도<br>(Accuracy) | 정밀도<br>(Precision) | 재현율<br>(Recall) | F1-점수<br>(F1-Score) |
|---------------|------|-------------------|--------------------|-----------------|---------------------|
| Random Forest |      | 0.9328            | 0.9481             | 0.9760          | 0.9618              |
| SVM Ensemble  |      | 0.8186            | 0.8252             | 0.9610          | 0.8879              |
| KNN Ensemble  |      | 0.8027            | 0.8277             | 0.9321          | 0.8768              |
| RNN-LSTM      |      | 0.8212            | 0.8221             | 0.9986          | 0.9017              |
| RNN-GRU       |      | 0.8259            | 0.8281             | 0.9938          | 0.9053              |
| CNN           |      | 0.8236            | 0.8238             | 1.0000          | 0.9034              |



<그림 2> 모형별 정확도, 정밀도, 재현율, F1-점수

사 결과로 인한 피소 등으로 막대한 경제적 손실이 발생할 수 있다(Atiya, 2001, 929). 그러므로 이 오류의 발생 가능성을 인지하고 있다면 부실기업을 정상기업으로 예측하는 것을 방지할 수 있다(Ribeiro, Silva, Vieira, Gaspar-Cunha, & Das Neves, 2010, 5). 또한, 이러한 재현율은 실제 분류대상을 분류기가 얼마나 성공적으로 분류하는지를 나타내므로 분류기의 완결성(Classifier's Completeness)으로 정의되는 중요한 평가척도라고 할 수 있다(Sun & Vasarhelyi, 2018, 182). 이러한 재현율의 관점에서 딥러닝 모형들은 다른 머신러닝 앙상블 모형보다 한계기업을 예측하는 데 있어서 탁월한 성과를 보인다고 할 수 있을 것이다.

## V. 결론

### 1. 연구 요약과 시사점

기업 부실화는 이전부터 회계와 재무 분야에서 활발하게 연구되고 있는 주제로, 기업 부실화가 해당 기업뿐만 아니라 기업의 이해관계자와 국가 경제에 부정적인 영향을 미칠 수 있으므로 그 중요성이 크다고 할 수 있다. 본 연구는 최근 기업 부실화 예측 분야에 분석방법으로 주목받고 있는 머신러닝 기반의 여러 모형을 적용하여 부실기업의 분류 중 하나인 한계기업을 예측하고자 하였다. 이는 기존의 기업 부실화를 예측하는 연구가 그 예측대상을 부도기업으로 한 연구가 주를 이루고 있어 상대적으로 한계기업 예측을 위한 연구는 적으며, 국내의 경제 상황에 적합한 부실기업의 범주를 활용하여 예측을 실시할 필요가 있다는 판단에서 비롯되었다.

머신러닝에 기반하여 부실기업을 예측한 선행연구들을 검토한 결과, 많은 연구에서 단일 머신러닝 모형을 활용하였을 경우보다 다수의 분류기를 결합한 앙상블 모형이 우수한 예측 성능을 가짐을 시사하였다. 또한, 다양한 분야에서 그 유용성이 검증된 딥러닝 모형을 적용한 연구의 수가 부실기업 예측 분야에서 그 비중이 상대적으로 작다는 사실을 발견할 수 있었다. 본 연구에서는 이러한 딥러닝 모형을 한계기업 예측에 적용하여 그 성능을 측정하고 많은 선행연구에서 우수한 성능을 가지는 것으로 나타난 머신러닝 앙상블 모형과 그 성과를 비교하였다. 이를 통해 딥러닝 모형들이 한계기업을 예측하는데 그 유용성이 있음을 제시하고자 하였다.

분석에 사용한 데이터는 KISVALUE에 공시된 KOSPI, KOSDAQ, KONEX 및 외부감사 대상기업의 2017~2019년

3개년의 기업 재무데이터이다. 이는 외부감사를 통해 신뢰성이 확보되었을 뿐만 아니라 기본적으로 머신러닝 모형의 학습에 필요한 최소 데이터 수 기준을 충족하기 위한 것이다. 재무 데이터는 기업의 재무제표에 기반한 재무비율 변수로 구성되어 있으며, 이전부터 기업부실화 예측을 위한 선행연구들에서 독립변수로 활용된 비율들을 본 연구에서도 활용하였다. 그리고 적절한 데이터 전처리와 통계적 방법에 따른 변수선정 과정을 수행하였다. 분석을 위해 머신러닝 앙상블 모형은 랜덤포레스트, 서포트 벡터 머신 앙상블 모형, K-최근접 이웃법 앙상블 모형을, 딥러닝 모형으로는 순환신경망 모형에 LSTM과 GRU를 결합한 RNN-LSTM과 RNN-GRU, 그리고 합성곱 신경망 모형을 사용하였다. 모형들의 예측력을 평가하기 위한 척도로는 정확도, 정밀도, 재현율, F1-점수를 사용하였다.

분석 결과 정확도, 정밀도, F1-점수의 관점에서는 머신러닝 앙상블 모형인 랜덤 포레스트가 가장 우수한 예측 성능을 보이며, 그다음으로 딥러닝 모형들이 전반적으로 우수한 성능을 가지는 것으로 나타났다. 반면, 재현율의 관점에서는 딥러닝 모형들이 가장 우수한 성능을 보이는 것으로 나타났다. 본 연구에서는 여러 척도 중 재현율로 예측 성능을 평가하였는데, 재현율은 실제 한계기업인 경우(FN)에 초점을 맞추고 있어 이를 토대로 예측 성능을 평가한다면 실제 한계기업을 예측하지 못하였을 경우 발생할 수 있는 부정적 결과를 방지할 수 있기 때문이다.

이러한 연구결과를 토대로 본 연구는 다음과 같은 학문적·실무적 시사점을 가진다. 먼저, 학문적 관점에서 본 연구는 부실기업 예측에 딥러닝 모형을 적용하여 그 유용성을 검증하였다. 구체적으로, 머신러닝 앙상블 모형들의 성능과 비교하여 딥러닝 모형들이 더 좋은 예측 성능을 가질 수 있음을 보여주었다. 이는 딥러닝 모형이 추가 연구를 통해 부실기업 예측 분야에서 더욱 유용한 역할을 할 수 있는 가능성을 제시하였다는 점에서 기여점이 있다. 실무적 관점에서 본 연구는 국내 상황에 적합한 부실기업 범주인 한계기업을 그 예측대상으로 함으로써 우리나라의 경제 실정에 맞는 기업 부실화 연구를 수행하였다. 즉, 계속기업들 사이에서 어떠한 특성을 가진 기업이 관리대상으로 분류되어야 하는지를 보였다는 점에서 기여점이 있다.

### 2. 연구 한계와 향후 연구 방향

이러한 기여점에도 불구하고 본 연구에는 다음과 같은 한계점이 존재한다. 먼저, 기업과 관련된 변수 중 대내적 변수인 재무비율만을 이용하여 한계기업을 예측하고자 하였다. 기업의

성과는 기업 그 자체의 운영 성과 이외에도 다양한 대외적인 요인과 환경적 변화에 영향을 받는 것이 많은 연구를 통해 제시된 바 있으나, 본 연구에서는 이러한 기업 외적인 변수는 모형들의 입력변수로 활용하지 않았다. 따라서 향후에는 기업의 성과에 영향을 미치는 환경적 요인들을 고찰하고 예측을 위한 변수로 활용할 필요가 있을 것으로 사료된다.

또한, 본 연구에서는 기업의 회계정보만을 활용하여 한계기업을 예측하고자 하였다. 회계정보는 기업의 성과를 나타내는데 목적적합한 정보이고 기업의 미래 성과에 대해 예측력을 가진다. 하지만 본질적으로 이러한 회계정보는 역사적 데이터(Historical Data)이므로 기업의 주가와 같은 시장정보가 가지는 적시성, 미래지향성 등이 부족하다는 단점이 존재한다. 그러므로 기업과 관련된 이러한 시장정보를 포함하여 분석한다면 모형들의 예측력을 향상시킬 수 있을 것으로 기대된다.

마지막으로 본 연구에서 분석에 사용한 데이터는 일정한 기업 규모 이상의 외부감사 대상기업 및 상장기업만으로 구성하였다. 우리나라 경제는 이러한 기업들보다도 중소기업이 그 절대적인 비중을 가지고 있을 뿐만 아니라 경제 상황에 따라 기업 부실화로 이어지는 가능성이 중소기업에서 더 높다는 점을 감안할 때, 본 연구는 중소기업을 분석대상에 포함하지 않아 다소 편향된 연구결과를 제시할 가능성을 내포하고 있다. 향후에는 이러한 중소기업만을 대상으로 하거나 혹은 중소기업을 분석대상에 포함하여 연구를 수행할 필요가 있을 것이다.

## 참 고 문 헌

- 강순심, & 김정재. (2014). IFRS도입이후 분·반기 보고기준에 따른 연결 및 별도재무제표의 가치관련성 분석—유가증권시장과 코스닥시장의 비교—. *경영연구*, 29(1), 223-261.
- 권혁진, 이동규, & 신민수. (2017). RNN(Recurrent Neural Network)을 이용한 기업부도예측모형에서 회계정보의 동적 변화 연구. *지능정보연구*, 23(3), 139-153.
- 김명중. (2009). 기업부실 예측 데이터의 불균형 문제해결을 위한 앙상블 학습. *지능정보연구*, 15(3), 1-15.
- 김선배, 박성중, & 김승일. (2016). 비상장 중소기업의 감가상각방법과 내용연수 변경이 법인세 등의 효과에 의한 재무수치와 재무비율에 미치는 영향—DK사의 사례—. *경영연구*, 31(4), 1-26.
- 김성환, 박전식, & 전성민. (2011). 대출기관의 부도 의사결정과 부실예측 모형의 내생성. *경영연구*, 26(1), 99-132.
- 김승수, & 김종우. (2018). 비정형 정보와 CNN 기법을 활용한 이진 분류 모델의 고객 행태 예측. *지능정보연구*, 24(2), 221-241.
- 김승혁, & 김종우. (2007). Modified Bagging Predictors를 이용한 SOHO 부도예측. *한국지능정보시스템학회논문지*, 13(2), 15-26.
- 김종화, 최중후, & 강창완. (2019). 순환신경망 모형을 활용한 시계열 비교예측. *Journal of the Korean Data Analysis Society*, 21(4), 1771-1779.
- 김진백, & 이준섭. (2000). 인공지능 기법을 이용한 중소기업 부도예측에 있어 현금흐름변수의 유용성 검증. *대한경영학회지*, 26, 229-250.
- 민성환. (2014). 개선된 배깅 앙상블을 활용한 기업부도예측. *지능정보연구*, 20(4), 121-139.
- 민성환. (2016). 부도예측을 위한 KNN 앙상블 모형의 동시최적화. *지능정보연구*, 22(1), 139-157.
- 박종원, & 안성만. (2014). 재무비율을 이용한 부도예측에 대한 연구: 한국의 외부감사대상기업을 대상으로. *경영학연구*, 43(3), 639-669.
- 방성혁, 배석현, 박현규, 전명중, 김제민, & 박영택. (2018). 순환신경망 기반의 사용자 의도 예측 모델. *정보과학회논문지*, 45(4), 360-369.
- 배재권. (2010). Voting 알고리즘과 인공신경망을 이용한 부도예측을 위한 통합알고리즘. *한국비즈니스리뷰*, 3(2), 79-101.
- 송양호, & 정성필. (2011). 한계기업의 현황 및 회생방안 고찰. *동북아법연구*, 5(2), 181-207.
- 엄하늘, 김재성, & 최상욱. (2020). 머신러닝 기반 기업부도위험 예측모델 검증 및 정책적 제언: 스테킹 앙상블 모델을 통한 개선을 중심으로. *지능정보연구*, 26(2), 105-129.
- 오세경, 최정원, & 장재원. (2017). 빅데이터를 이용한 딥러닝 기반의 기업부도예측 연구. *금융연구 working paper*, 2017(8), 1-113.
- 오영택, & 정성필. (2011). 국내 한계기업의 구조조정을 위한 법과 정책의 변화와 그 대안을 위한 서론적 고찰. *법학연구*, 33, 151-170.
- 오우석, & 김진화. (2017). 인공지능기법을 이용한 기업부도 예측. *산업융합연구*, 15(1), 17-32.
- 윤호중. (2019). 머신러닝을 이용한 한국 스포츠산업 기업의 부실 예측에 관한 연구. *한국체육학회지*, 58(6), 165-176.

- 이건창. (1993). 기업도산 예측을 위한 통계적 모형과 인공지능 모형간의 예측력 비교에 관한 연구: MDA, 귀납적 학습 방법, 인공지능망. *한국경영과학회지*, 18(2), 57-81.
- 이기영, & 우석진. (2015). 공적 신용보증이 한계기업의 생존에 미치는 효과. *재정학연구*, 8(4), 71-90.
- 이선민, 선영규, 이지영, 이동구, 조은일, 박대한, 김용범, 심이삭, & 김진영. (2019). LSTM과 GRU 딥러닝 IoT 파워미터 기반의 단기 전력사용량 예측. *한국인터넷방송통신학회 논문지*, 19(5), 79-85.
- 이인로, & 김동철. (2015). 회계정보와 시장정보를 이용한 부도 예측모형의 평가 연구. *재무연구*, 28(4), 624-665.
- 이재식, & 한재홍. (1995). 인공신경망을 이용한 중소기업도산 예측에 있어서의 비재무정보의 유용성 검증. *한국전문가시스템학회지*, 1(1), 123-134.
- 이찬호, 최지혜, 김민승, 최정환, & 성태웅. (2020). 기업구조조정 혁신을 위한 선제적 한계기업 예측모형에 관한 연구. *기술혁신학회지*, 23(4), 637-667.
- 이화득, & 육근구. (2004). 분기보고의 시행과 반기재무제표 공시의 정보효과에 관한 연구. *경영연구*, 19(3), 241-266.
- 조성표, & 류인규. (2007). 불황기에서 회계정보에 의한 기업 부실화 예측. *경영연구*, 22(1), 1-32.
- 차성재, & 강정석. (2018). 딥러닝 시계열 알고리즘 적용한 기업 부도예측모형 유용성 검증. *지능정보연구*, 24(4), 1-32.
- 최하나, & 이동훈. (2013). 앙상블 SVM모형을 이용한 기업 부도 예측. *한국데이터정보과학회지*, 24(6), 1113-1125.
- Alexandropoulos, S. A. N., Aridas, C. K., Kotsiantis, S. B., & Vrahatis, M. N. (2019). A deep dense neural network for bankruptcy prediction. In *International conference on engineering applications of neural networks* (pp. 435-444). Springer, Cham.
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4), 589-609.
- Arratia, A., & Sepúlveda, E. (2019). Convolutional neural networks, image recognition and financial time series forecasting. *Workshop on Mining Data for Financial Applications*, Springer, Cham, 60-69.
- Atiya, A. F. (2001). Bankruptcy prediction for credit risk using neural networks: A survey and new results. *IEEE Transactions on Neural Networks*, 12(4), 929-935.
- Barboza, F., Kimura, H., & Altman, E. (2017). Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83, 405-417.
- Bengio, Y., Courville, A., & Vincent, P. (2013). Representation learning: A review and new perspectives. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(8), 1798-1828.
- Caballero, R. J., Hoshi, T., & Kashyap, A. K. (2008). Zombie lending and depression restructuring in Japan. *American Economic Review*, 98(5), 1943-1977.
- Dietterich, T. G. (1997). Machine-learning research. *AI Magazine*, 18(4), 97-97.
- Hosaka, T. (2019). Bankruptcy prediction using imaged financial ratios and convolutional neural networks. *Expert System with Applications*, 117, 287-299.
- Kim, H. S., & Sohn, S. H. (2010). Support vector machines for default prediction of SMEs based on technology credit. *European Journal of Operational Research*, 201(3), 838-846.
- Le, H. H., & Viviani, J. L. (2012). Predicting bank failure: An improvement by implementing a machine-learning approach to classical financial ratios. *Research in International Business and Finance*, 44, 16-25.
- LeCun, Y., & Bengio, Y. (1995). Convolutional networks for images, speech, and time series. *The Handbook of Brain Theory and Neural Networks*, 3361(10), 3-14.
- Lee, T. S., Chiu, C. C., Lu, C. J., & Chen, I. F. (2002). Credit scoring using the hybrid neural discriminant technique. *Expert Systems with Applications*, 23(3), 245-254.
- Mai, F., Tian, S., Lee, C., & Ma, L. (2019). Deep learning models for bankruptcy prediction using textual disclosures. *European Journal of Operational Research*, 274, 743-758.
- Mikolov, T., Karafiát, M., Burget, L., Černocký, J., & Khudanpur, S. (2010). Recurrent neural network based language model. *INTERSPEECH-2010*, 1045-1048.

- Odom, M. D., & Sharda, R. (1990). A neural network model for bankruptcy prediction. *1990 IJCNN International Joint Conference on Neural Networks*, 163–168.
- Ohlson, J. S. (1980). Financial ratios and probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1), 109–131.
- Ribeiro, B., Lopes, N., & Silva, C. (2010, July). High-performance bankruptcy prediction model using graphics processing units. *The 2010 International Joint Conference on Neural Networks (IJCNN)*, 1–7.
- Ribeiro, B., Silva, C., Vieira, A., Gaspar-Cunha, A., & Das Neves, J. C. (2010). Financial distress model prediction using SVM+. *The 2010 International Joint Conference on Neural Networks (IJCNN)*, 1–7.
- Shin, K. S., & Lee, T. S. (2005). An application of support vector machines in bankruptcy prediction model. *Expert Systems with Applications*, 28(1), 127–135.
- Sun, T., & Vasarhelyi, M. A. (2018). Predicting credit card delinquencies: An application of deep neural networks. *Intelligent Systems in Accounting, Finance and Management*, 25(4), 174–189.
- Vochozka, M., Vrbka, J., & Suler, P. (2020). Bankruptcy or success? The effective prediction of a company's financial development using LSTM. *Sustainability*, 12(18), 1–17.
- Yeh, S., Wang, C., & Tsai, M. (2015). Deep belief networks for predicting corporate defaults. *2015 24th Wireless and Optical Communication Conference (WOCC)*, 159–163.
- Zmijewski, M. E. (1984). Methodological issues related to the estimation of financial distress prediction models. *Journal of Accounting Research*, 22, 59–82.

# A Study on the Prediction Model for Insolvent Companies Based on Deep Learning

Jae-Hyeok Jo \*

Eun-Ju Ahn \*\*

Sungsu Kim\*\*\*

## 〈Abstract〉

Predicting insolvent companies is a research topic that has been important in accounting and finance. Especially, due to the rapidly changing business environments and the recent COVID-19 pandemic, many domestic companies are facing financial adversity. Thus, the necessity of research on corporate insolvency is being emphasized. As a related research, there is a prediction of corporate bankruptcy, however, a bankrupt company is the company whose business activities have been suspended, and there is a limitation in which it is inappropriate to determine which companies show signs of bankruptcy among continuing companies. Therefore, marginal company, one of the categories of insolvent companies, is selected as the prediction target. Marginal companies are the firms that are operating income interest compensation ratio are less than 1 for three consecutive years, and are engaged in business activities but have not consistently secured adequate profits. In this study, deep learning techniques are used to predict them. It is one of the machine learning techniques that has recently attracted attention because of its excellence in various fields. Nonetheless, has not been applied in research to predict marginal companies. This study applies RNN and CNN among deep learning techniques using several financial ratios as independent variables. Their performance are compared with machine learning ensemble models that have been reported to have excellent predictive power in previous studies. As a result of analysis on corporate data from 2017 to 2019 as training and test data, deep learning models such as RNN-LSTM, RNN-GRU, and CNN are better in forecasting of marginal companies than the ensemble models in terms of Recall score. Therefore, the deep learning models are expected to become widely used in the prediction of marginal companies in the future.

**Key words** : Corporate Insolvency, Deep Learning, Machine Learning, Ensemble Model, Marginal Company Prediction

\* Doctoral Student, School of Business Administration(E-mail: jjg7578@knu.ac.kr): First Author

\*\* Doctoral Student, School of Business Administration(E-mail: dmswn8808@naver.com): Co-Author

\*\*\* Associate Professor, School of Business Administration(E-mail: sungukim@knu.ac.kr) : Corresponding Author